제약-바이오 R&D의 AI 전환(AX) 역설 극복을 위한 자기 진단형 데이터 거버넌스 프레임워크 : 비순환 직교 GNN기반 벤치마크 착시 감사 및 의사결정 지원 시스템

김 혜 원

서론

제약-바이오 산업을 비롯한 고위험 R&D 조직들이 신약 후보 물질 발굴을 위해 딥러닝 및 그래프 신경망(GNN)을 공격적으로 도입하고 있으나, 벤치마크에서 높은 예측 정확도(AUROC)를 기록한 AI 모델의 도입에 대하여 AI 전환의 역설(AX Paradox)이 반복되고 있습니다. 분자 그래프 신경망(GNN) 기반의 가상 스크리닝(Virtual Screening)및 약물 속성 예측 모델은 학습 벤치마크에 내재된 물리화학적 위상적 아티팩트(Artifact)를 타깃 결합 신호로 오인하는 지름길 학습 병리(Short cut Learning)를 겪고 있습니다.

이 아티팩트는 분자를 구성하는 원자와 입자들 간의 화학 결합 관계를 표현하는 간선, 정수형 데이터로 구성되는 인접행렬과 거리행렬이라는 기본 요소로 이루어지는 화학 그래프 이론(Chemical Graph Theory)을 기반으로 만들어지는 위상지표(Topological indices)가 차원 축소 및 정보 손실, 위상적 축퇴를 포함하며 분자 내 비결합성 상호작용을 반영하지 못하는 등의 원인으로 발생합니다.

대표적으로 고속 스크리닝 데이터셋에는 실제 약효 결합력이 없으면서도 과도한 지용성(LogP > 5)이나 평면 다중고리 구조 때문에 수용액 내에서 엉겨 붙어 활성으로 오판되는 시험관 아티팩트(Assay Trap)가 다수 존재합니다. AI 도입 과정에서 물리화학적 지름길(Shortcut)을 걸러내지 못하면 가짜 상위권 후보 물질에 R&D 예산을 투입하는 의사결정 오류를 유발합니다.

모델이 학습하는 과정에서 1차원의 쉬운 물성, 혹은 편향에 의존할 경우 핵심 약효 구조를 판별해야 하는 신경망의 내부 구조 표현 분산이 소멸하는 표현의 붕괴가 발생하기에 의도적으로 이런 신호들은 분류를 하여 보관 후 추론에 사용하면 신규 타겟 앞에서 선별력을 상실하지 않습니다.

데이터셋 차원에서 보완하기 위해서는 벤치마크를 전수조사하여 인위적으로 구성하는 접근법이 있고, 모델의 차원에서는 어떤 신경망을 사용할지, 화학 공간을 다루기에 적합한 전제를 가진 모델인지 고민할 수 있습니다. 하지만 이 둘은 분리하여 판단할 수 없습니다. 특히 신경망을 다루는 경우 신경망에 적합한 입력 데이터셋을 만들어야 원활한 AX전환이 가능합니다.

입력 데이터를 모델에 맞추기 위해 모으는 과정에서는 다중 데이터베이스 통합 시 심슨의 역설을 해결하는 접근이 필요합니다. 이종 R&D데이터베이스(예 : 양성 기저율이 극히 낮은 탐색 스크리닝 DB와 기저율이 높은 임상-부작용 DB)를 전사적으로 통합할 때, 기저율 격차를 통제하지 않는 경우 순수 구조 점수와 물성 편향 점수 사이에 거짓된 양의 상관관계가 유도되는 현상을 확인하였습니다.

이는 다양한 raw데이터를 기관에서 모으는 과정에서 쉽게 발생할 수 있는 일이며, 역시나 AX전환의 병목이 됩니다.

본 연구는 디자인 과학 연구 방법론에 입각하여, 고가의 AI 백본 모델을 대형화하는 대신 동일한 AI엔진(201,733개 백본 파라미터 고정)하에서 데이터 진단 및 직교 분리 거버넌스만을 적용할 때 R&D 의사결정 품질이 어떻게 복원되는지를 입증합니다.

설계 원칙 Design Principles

<기술 모듈 구성요소>

1. 무손실(Zero-Deletion) 프로토콜

원본 데이터를 인위적으로 삭제하는 경우 화학 공간의 왜곡을 초래하는 기존 필터링 방식
대신 모든 분자를 보존합니다. 화학 자산 손실 방지 및 감사 추적성을 확보할 수 있습니다.

2. 5차원 편향 정량화 프로토콜

분자의 크기에 따른 어텐션 엔트로피 보정 온도, 골격 독점 역가중치, 물성(분자량, 지용성,
극성 표면적, SP3 탄소 분율) 및 시험관 응집/막투과 함정 지시자로 구성된 5차원 편향
텐서를 분리 구축합니다. 소형, 거대 후보 물질 간 평가 형평성을 확보, R&D 후보 물질
포트폴리오의 다양성을 유지, Wet-lab 실패 고위험군(위양성)을 사전 배제할 수 있습니다.

3. 비순환 양갈래 직교 분리 및 심슨의 역설 통제 학습

백본 인코더 뒤단에 순수 구조 헤드와 물성 편향 흡수 헤드를 병렬로 부착합니다. 다중 R&D코퍼스 통합 시 기저율 격차로 발생하는 심슨의 역설을 제거하기 위해, 각 태스크 채널 별 배치 평균을 중심화한 뒤 두 헤드 간 직교성을 강제하는 정규화와 어텐션 엔트로피 샤프닝을 결합하여 학습합니다.

4. 절편 보존 탈편향 추론 및 내부 붕괴 감사

불균형 데이터를 학습할 때 음수 기저 절편이 두 헤드에 분할 내재화되는 현상을 보정하기 위해, 추론 단계에서 편향 헤드의 평균 절편은 유지하고 분자별 편향 편차만 도려내는 보정식을 적용합니다.이렇게 산출된 순수한 구조의 로짓 표준편차와 정규화 어텐션 엔트로피를 측정하여 모델이 표현 붕괴에 빠졌는지 자체 감사(Self-Auditing)합니다.

5. 수리적 상한선 검증 기반 조기 인식된 의사결정

산출된 예측 점수를 바탕으로 전체 예측 total, 순수 구조 struct, 물성 단독 모드의 조기 인식 지표(BEDROC 및 EF1%, EF5%)를 비교합니다. 이때 상위 적중 건수가 허용하는 이론적 상한선(Ceiling)부합 여부를 함께 검증하여 지표 산출 과정의 수리적 무결성을 보장합니다.

무손실 비순환 직교 보정 아키텍쳐 Non-Circular Orthogonal GNN은 V1의 경우 위 거버넌스를 미적용한 단일 MUV 코퍼스 17채널을 학습했습니다(859.6 KB). V2의 경우 5대

코퍼스 37,792건 59채널을 학습하며 직교 거버넌스를 적용했습니다(875.0KB). 모두에서 핵심 의사결정 엔진인 GNN 백본 파라미터를 201,733개로 100% 동일하게 고정합니다.
.V2는 백본 확장 비용 없이 오직 출력 분류 및 편향 분리 헤드에서 3,980개 파라미터(+1.88%)만 활용하여 전사적 데이터 정렬을 수행합니다.

제약 R&D의 AX 실패를 막기 위해 4단계 비순환 직교 거버넌스로 데이터셋의 편향을 분리-진단하는 방법론(Methodology)을 제시하며 백본 크기는 201,733개로 통제된 프로토타입(V1, V2)을 통해 그 백본 고도화 효과를 배제하고 방법론의 순수 효과를 입증하며 작동가능성을 개념 증명(PoC)합니다.
현업에서는 각 기업의 자체 R&D 데이터와 사내 AI 모델에 본 방법론을 이식할 수 있습니다.

본 연구의 목적은 알고리즘의 교체 관점에서 특정 타깃에 국한된 단일 예측 모델이나 완성형 가중치를 배포하는 것이 아니라 향후 분산된 데이터셋을 데이터 플랫폼이 모아 모델을 학습하고, 학습된 대형 모델의 데이터를 공유하는 과정에서 발생할 수 있는 문제를 고려한 모델에 맞춰진 통합 데이터셋을 구축하는데 집중한 진단 도구가 필요함을 제시하며, 도구 구현 방법론의 실행가능성을 백본의 신경망 크기를 고정한 통제 실험을 통해 제안한 실증적으로 검증합니다.

방법론

제안한 방법론은 실제 신경망의 표현 붕괴를 막고 R&D 선별 효율을 회복시킬 수 있는지 가능성을 확인하기 위해, 백본 구조를 통제한 두 개의 실험 프로토타입(V1 vs V2)을 구축하여 개념 증명(PoC)을 수행했습니다.

통제 변인 설계를 위한 프로토타입 불균형 정렬 명세

방법론의 순수한 효과를 분리하여 측정하기 위해서 방법론을 적용하기 전 대조군 프로토타입(V1, 단일 MUV 코퍼스 17채널 학습)과 방법론 적용 실험군 프로토타입(V2, 5대 코퍼스 37,792건 59채널 직교 학습)의 4계층 GINEConv 백본 파라미터를 201,733개로 100% 동일하게 고정했습니다.

이것은 분자 벤치마크 데이터셋이 가진 태생적인 불균형 딜레마를 신경망 백본 확장 없이 데이터 정렬과 직교 분리 방법론만으로 해결할 수 있는지 검증하기 위한 통제 변인 설계입니다.

1. 대조군(V1) 단일 코퍼스의 한계

MUV(Maximum Unbiased Validation)코퍼스는 기존 합성 디코이(Synthetic Decoy) 기반 벤치마크들이 단순 물리화학적 기술자(Descriptor)나 분자 골격 간의 거리 측정만으로도 활성과 비활성이 쉽게 분리가 되는 지름길(Shortcut) 한계를 극복하기 위해 근접 이웃 공간 통계(Spatial statistics)를 기반으로 활성 분자와 디코이 간의 근접 이웃 거리 편향을 엄격히 억제한 데이터셋입니다. 그러나 활성 분자 당 디코이 비율이 극단적으로 치우친 클래스 불균형 구조를 갖게 되었습니다.

코퍼스 구분 (MUV 17채널)	분자 수 (N)	유효 라벨 수	양성 / 비활성 라벨 수	활성:디코이 비율 (기저율)
MUV 원본 전체 (V1 학습)	93,087건	249,886개	489개 / 249,397개	1 : 510.0 (0.1957%)

위 전수 검증 결과에서 확인 되듯, 대조군 V1이 학습한 MUV 원본 전체(93,087건)는 17개 채널의 유효 라벨 249,886개 중 실제 양성(Active) 라벨이 단 489개에 불과하고 비활성 디코이(Decoy)가 249,397개에 달해, 활성 대 디코이 비율이 1:510.0(양성 기저율 0.1957%, 약 0.20%)이라는 극단적 희소성을 보였습니다.

2. 실험군(V2) 다중 코퍼스 확장 시 양성 라벨 지배 현상과 심슨의 역설

실험군(V2)은 MUV 단독 학습의 표현 붕괴를 타개하고 소형, 거대 분자 영역으로 화학 공간을 확장하기 위해, MUV의 활성 라벨 489개를 100% 보존한 25,000건 서브셋(유효 라벨 67,274개, 활성:디코이 = 1:136.6, 기저율 0.7269%)을 구축한 뒤, 독성 및 시판 약물, 임상 코퍼스인 Tox21, BBBP, ClinTox, SIDER를 병합하여 총 59개 채널의 다중 코퍼스를 구성했습니다.

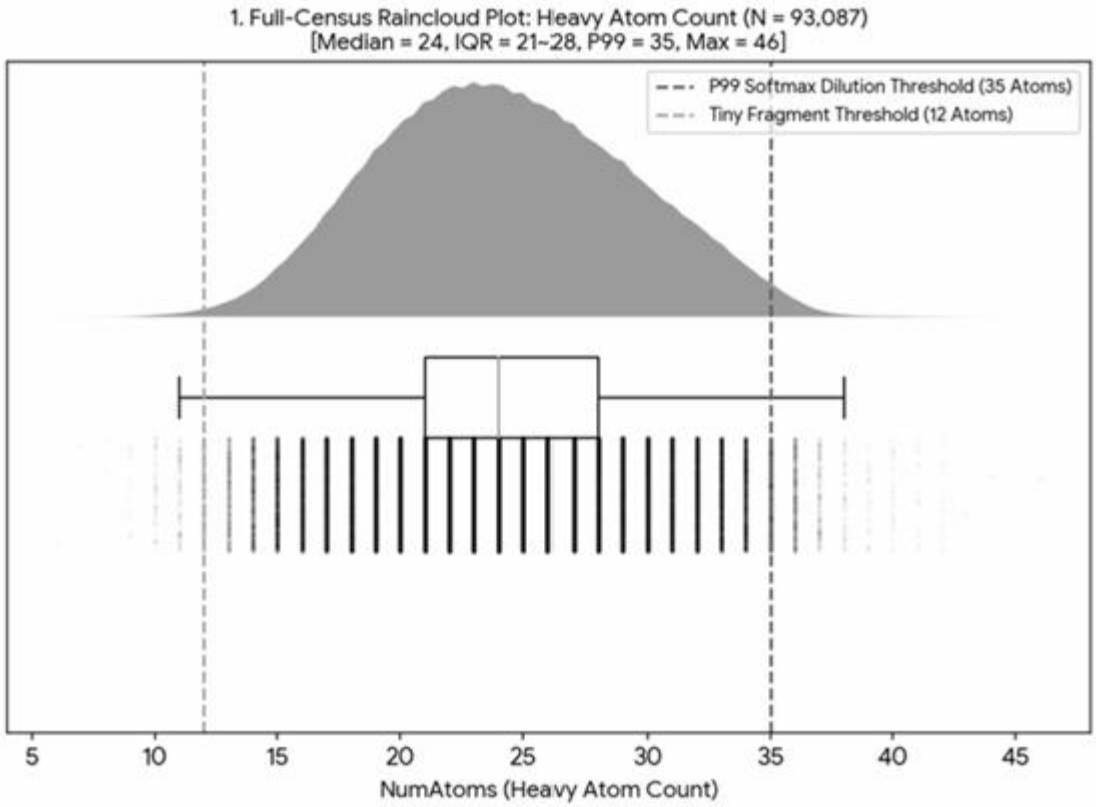
통합 서브 코퍼스 (59채널)	분자 수 (채널 수)	유효 라벨 수	양성 / 비활성 라벨 수	활성:비활성 비율 (기저율)
MUV (활성 전수보존)	25,000건 (17ch)	67,274개	489개 / 66,785개	1 : 136.6 (0.73%)
Tox21 (독성 스크리닝)	7,823건 (12ch)	77,864개	5,858개 / 72,006개	1 : 12.3 (7.52%)
SIDER (시판약물 부작용)	1,427건 (27ch)	38,529개	21,868개 / 16,661개	1 : 0.76 (56.76%)
BBBP (혈뇌장벽 투과)	2,039건 (1ch)	2,039개	1,560개 / 479개	1 : 0.31 (76.51%)
ClinTox (임상 독성·승인)	1,480건 (2ch)	2,960개	1,498개 / 1,462개	1 : 0.98 (50.61%)

위 표를 보면 분자 수(N) 기준으로 보면 SIDER(1,427건, 전체 분자의 약 3.8%), ClinTox(1,480건, 3.9%), BBBP(2,039건, 5.4%)는 주력 코퍼스인 MUV(25,000건, 66.2%)에 비해 매우 미세하게 첨가된 수준이다. 그러나 전체 5대 코퍼스의 유효 라벨 총 188,666개 중 존재하는 전체 양성 라벨 31,273개의 출처를 분해하면 정반대의 현상이 나타났습니다.

분자 수의 66.2%를 차지하는 MUV (25,000건)가 제공하는 양성의 라벨은 489개입니다. 전체 양성 신호의 1.56%에 불과합니다.

반면 분자 수가 1,427건(3.8%)뿐인 SIDER는 결측치 없이 조밀하게 채워진 27개 멀티태스크 채널(유효 라벨 38,529개)과 높은 양성 비율(활성:비활성 = 1:0.76, 기저율 56.76%)로 인해 21,868개의 양성 라벨을 차지하여 전체 통합 코퍼스 양성 라벨(31.273개)의 69.93%를 단독으로 독점한다.

마찬가지로 2,039건의 단일 채널 데이터인 BBBP 역시 양성 1,560개 대 비활성 479개(1:0.31, 기저율 76.51%)의 역전된 구조를 가졌다.



MUV 93,087건 중원자 수 분포의 사분위수 범위(Raincloud Plot)

이러한 1 : 510.0의 불균형과 좁은 분자 크기 분포(중원자 수 21~28개 집중)하에서 단일 코퍼스만으로 GNN을 학습시킬 경우, 신경망은 전체 MUV 유효 라벨의 99.80%를 차지하는 비활성 디코이에서 활성(Active)판정이 나는 위양성(False Positive)손실 페널티를 회피합니다.

머신러닝(딥러닝은 인공신경망(ANN)구조를 깊게 확장한 머신러닝의 특화된 한 갈래이다.)의 손실 함수는 모델이 틀릴 때마다 벌점(Penalty)을 부여합니다. 여기서 말하는 손실 함수는 선형 회귀 모델의 추론 후 평가 수식과 상당 부분 겹치지만 특히 모델의 '학습시' 만들어지는 오차와의 거리 합이 가장 작은 기울기를 찾아가는 과정에서 사용됩니다.

예를 들면 시험에서 어느 한 명제에 대하여 998문제가 답이 X이고, 단 2문제만 O일 때, 학생은 굳이 O를 찾기 위해 시간과 자원을 쓰다가 감점을 2문제 이상 당하는 위험을 감수하기보다 모든 문제의 답을 X로 일괄 마킹하여 감점을 2문제 이상 당하지 않도록 회피하는 것과 유사합니다. 99.8%가 비활성인 환경에서는, 모델이 어설프게 양성을 맞히려고 시도하다가 비활성 분자를 건드려 큰 감점을 받는 것보다는 모든 분자는 비활성이라고 일괄 처리하여 추가 감점을 회피하는 것이 손실을 줄이는 가장 손쉬운 지름길이 됩니다. 신경망은 이때 진짜 분자 구조를 읽는 법을 배우는 대신 벌점을 피우기 위한 소극적 예측(이를 표현 붕괴라고 합니다.)으로 방향을 전환합니다.

이러한 경우 외부 ogbg-molhiv 데이터셋에서의 모든 입력에 대해 거의 똑같은 점수를 주는(결과값) 평균 -2.483, 표준편차 0.169 상태에 빠지게 됩니다. (모델이 전체 테스트셋 분자들에 대해 평균적으로 강한 음수 로짓(비활성)을 뱉음을 의미하며, 결과값이 퍼진 너비가 좁다는 것입니다.)

로짓은 신경망이 시그모이드나 소프트맥스를 거쳐 확률 0~1로 바꾸기 직전에 출력하는 날것의 점수입니다. 정상적으로 분포를 완성한 모델이라면 활성 분자를 볼 때는 큰 양수 +3.0, +0.5를 뱉어야 하고, 비활성 분자를 볼 땐 큰 음수 -3.0, -5.0을 뱉어서 점수의 편차가 넓게 벌어져야 합니다.

표준편차는 평균을 기준으로 하여 출력된 값(Y헷)이 얼마나 멀리 떨어져 있는지를 보여주며 출력 값들이 평균으로부터 넓게 퍼져있을수록 표준편차는 크다고 합니다. 표준편차가 0.169라는 것은 수백, 수천 개의 서로 다른 분자를 집어넣었는데도 모델이 내놓은 점수들 간의 차이가 0.2도 안되며 거의 한 점에 다닥다닥 뭉쳐있다는 뜻입니다. 이는 분자 그래프의 고유한 화학 구조적 특징(원자, 결합, 스캐폴드)을 보고 점수를 매기는 게 아니라, 구조적 차이 자체를 완전히 소거하는 상태로, 비활성 데이터가 99.8%에 달하는 극단적인 불균형 환경에서는 모델이 이 분자를 활성으로 판정할 경우 나타나는 위양성 손실 벌점이 너무 큽니다. 따라서 신경망이 이 리스크를 피하기 위해 분자 구조를 읽는 가중치를 0으로 다 뭉개고 모든 분자에 대해 일괄적으로 비활성(음수 로짓)에 해당하는 좁은 점수대만 뱉어내는 표현 붕괴를 선택한 것입니다.

ogbg-molhiv에서 V1 순수 구조 모드의 실측 ROC-AUC는 0.4921, P = 0.760입니다. molpcba 126개 타깃 V1 순수 구조(Struct, 17ch)모드의 평균 ROC-AUC 0.3920(EF1% 0.50x)는 실제 활성 분자에 비활성보다 더 낮은 점수를 준 역전이 관찰되었습니다.

ROC(Receiver Operating Characteristic Curve)곡선은 분류 임계값(Threshold)을 1.0에서 0.0까지 점진적으로 내릴 때, 모델이 진짜 정답을 얼마나 잘 건져내는지(재현율/진양성률, TPR)와 엉뚱한 오답을 얼마나 짚는지(위양성률, FRP)를 x-y 평면에 추적한 궤적입니다. y축은 활성이라고 표기한 것 중 진짜 활성이라고 올바르게 건져낸 비율을 표기하며 1.0에 가까워질수록 좋습니다.x축은 실제로는 비활성인 후보물질 중 활성이라고 엉뚱하게 분류한 비율로 0.0에 가까워질수록, 즉 왼쪽에 가까울수록 좋습니다. 각 분자에 대해 출력한 가능성을 바탕으로 임계점을 가장 엄격한 1.0에서 가장 널널한 0.0까지 서서히 내리면서 점을 찍어가면, 임계점을 1.0으로 둔다면 활성으로 인정을 받는 것 자체가 없습니다. 이때는 활성이 사실은 비활성인지, 혹은 제대로 활성이라고 확률을 제시한 것인지 판단할 수 없습니다(TPR = 0, FPR = 0). 기준점을 0.9, 0.8로 점점 낮추면서 점수가 높은 분자부터 활성이라고 소프트맥스 등은 결과를 냅니다. 만약 모델이 붕괴 없이 잘 학습되었다면, 실제

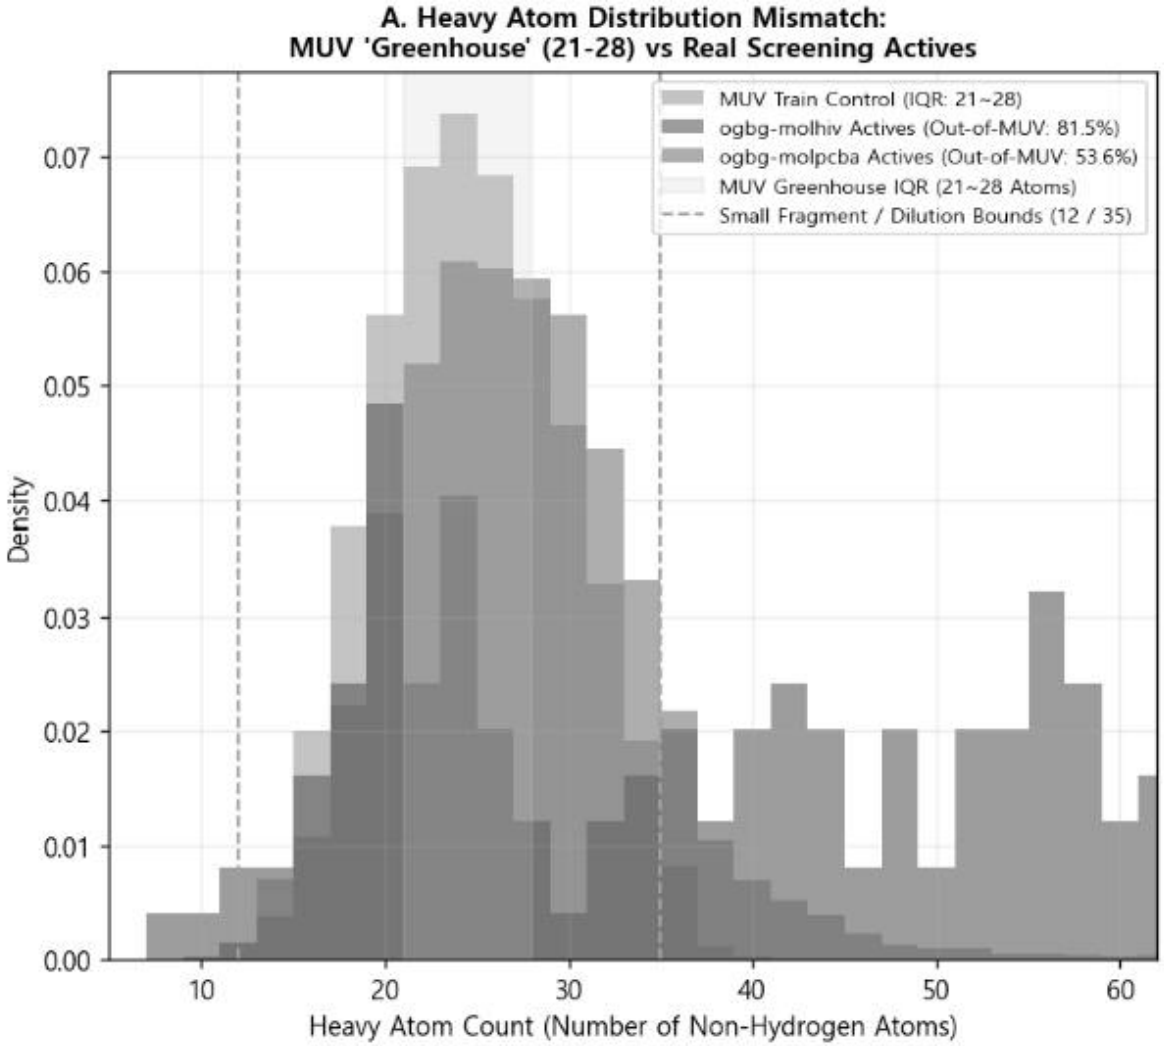
활성 분자에 높은 점수를 매겨두고 임계값을 내려갈수록 무작위로 비활성 오답을 섞지 않고 실제 활성부터 제시합니다. 즉 x축(FPR)은 증가하지 않고, y축(TPR)만 수직으로 상승하여 좌상단 (0,1)을 향해 치솟습니다. 모델이 표현 붕괴한 경우 점수가 무작위 노이즈거나 뭉쳐서 임계값을 내릴 때마다 똑같이 활성 판정이 난 분자이지만 그것이 위양성인 경우와 진양성인 경우가 함께 섞여서 올라오며 x가 늘어나는 만큼 y도 정비례하게 늘어나 대각선 (0, 0)에서 (1, 1)을 따라갑니다. 임계값이 0.0인 경우 모든 분자를 활성으로 판정합니다(비활성이라고 판정하는 것은 아닙니다.) 이땐 한 줄로 통일을 했기 때문에, 실제 정답을 모두 건져내지만(TPR = 1.0) 동시에 비활성 분자도 정답으로 분류(FPR = 1.0)합니다. 좌표는 (1, 1)에 도달하며 끝이 납니다.

AUC는 ROC곡선 아래쪽의 전체 면적을 말하며, 임계값을 어떻게 잡아도 모델이 전반적으로 얼마나 분류를 잘 해내는지를 0.0에서 1.0사이의 숫자 하나로 요약한 성적표입니다. 전체 데이터에서 활성 한 개와 비활성 한 개를 무작위로 뽑았을 때, 모델이 진짜 정답에 더 높은 확률을 주었을 가능성, 정답과 오답의 순위(Ranking)을 얼마나 올바르게 세우는가를 측정하는 지표입니다.

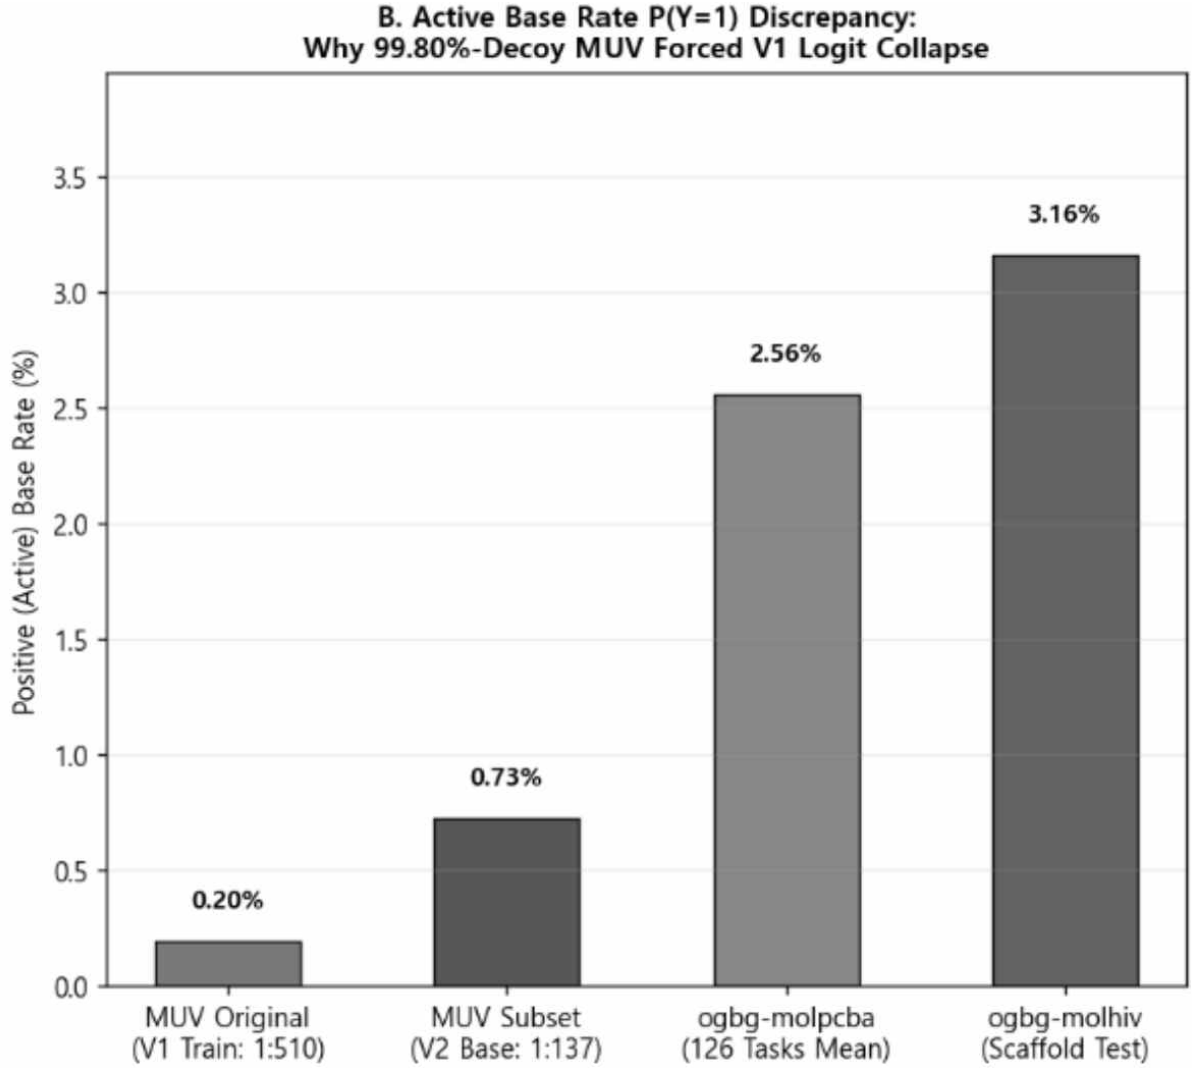
가로, 세로의 길이가 1인 정사각형 평면(0, 0)부터 (1, 1)까지 계산되므로 면적은 0과 1사이로 나옵니다. 1.0은 어떤 비활성 디코이보다도 모든 활성 분자의 점수가 항상 높습니다. 정답과 오답의 순서가 완벽하게 분리되어 면적이 거의 꽉 찬 상태이지만, 보통은 0.9정도가 좋은 성적이라고 볼 수 있습니다. 0.5는 임의로 뽑은 정답의 점수가 오답보다 높은 확률이 반반(50%)이라는 뜻으로 아무 의미가 없는 노이즈 분류기입니다. 0.5미만(0.49, 0.39 등 역전이 일어난 경우)에선 무작위로 찍는 것보다 못한 상태입니다. 정답보다 오답에 더 높은 점수를 부여하는 경향이 나타나서 모델 예측을 거꾸로 뒤집는 것이 나을 정도로 구조적 왜곡, 오판이 일어나고 있음을 의미합니다.

P = 0.760은 통계적으로 가설검정의 유의확률(p-value)를 말하며, 모델이 낸 성능 AUC 0.4921이 무작위로 찍은 0.5000과 통계적으로 차이가 있는지를 확인한 결과로, 귀무가설(H0)로는 '모델의 성능은 동전 던지기(무작위 추론, AUC = 0.5)와 다를 바가 없다로 설정하고 대립가설(H1)은 모델의 성능은 무작위 추론과 유의미하게 다르다고 설정할 수 있습니다. 이때, p = 0.760의 의미는 통계학적으로는 p < 0.05 (유의수준 5%)이하로 떨어져야 동전던지기와는 유의미하게 다르다고 판정하지만, p = 0.760이라는 것은 모델은 무작위로 추론하는데 (AUC = 0.4921), 우연한 표본 오차나 노이즈로 인해 AUC 0.4921같은 숫자가 나올 확률이 76%가 된다. 즉 우연한 결과가 아니라, 완벽한 무작위 난수 생성기가 너무 당연한 표본 오차 범위 내에서 헛수치를 낸 것이 맞음을 수학적으로 증명한 것입니다. 따라서 귀무가설을 기각하지 못함으로써 순수 구조 헤드는 분자 구조 정보를 학습하는데 완전히 실패하여 무작위 추론 상태에 머물러 있다는 것을 통계적으로 근거 바탕으로 제시할 수 있습니다.

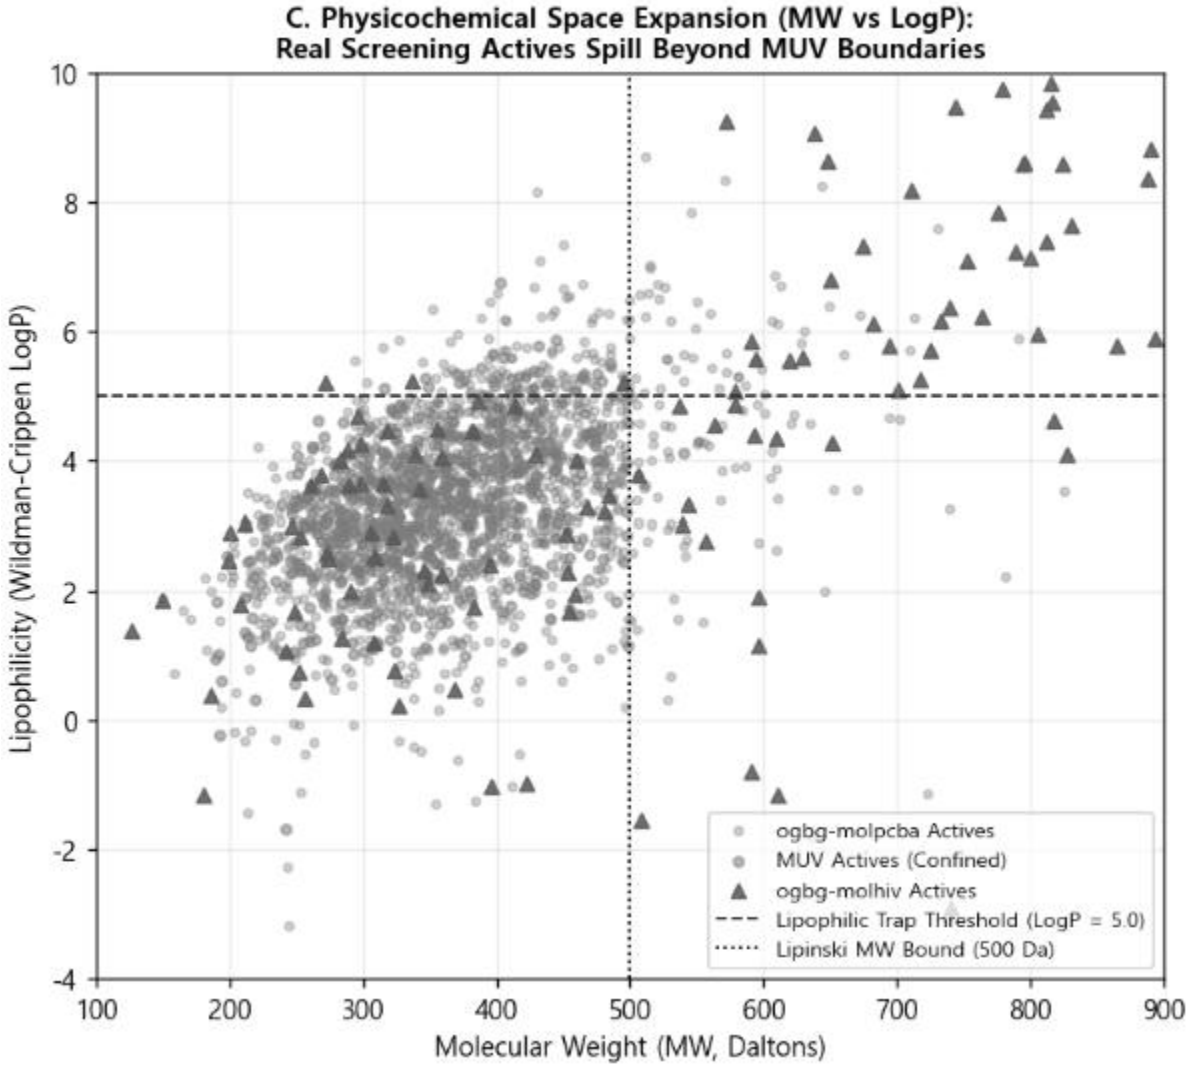
더 나은 결과를 만들어보기 위하여 모델의 구조(V1)를 유지한 채 코퍼스를 늘려보기로 했습니다. 단일 코퍼스 MUV로 학습한 기본 모델 V1이 외부 가상 스크리닝 벤치마크인 ogbg-molhiv와 ogbg-molpcba에서 무작위 추측 기준선 아래로 붕괴한 현상을 보완하기 위해서는 인위적으로 통제된 MUV의 실제 활성 물질이 풍부한 스크리닝 환경 간의 4가지 구조적 분포 괴리를 해결해야 한다는 판단 하에 결정하였습니다. 우선적으로 추론 데이터셋 ogbg-molhiv와 ogbg-molpcba을 비교하며 이를 보완할 데이터셋 선정의 원인을 설명하도록 하겠습니다.



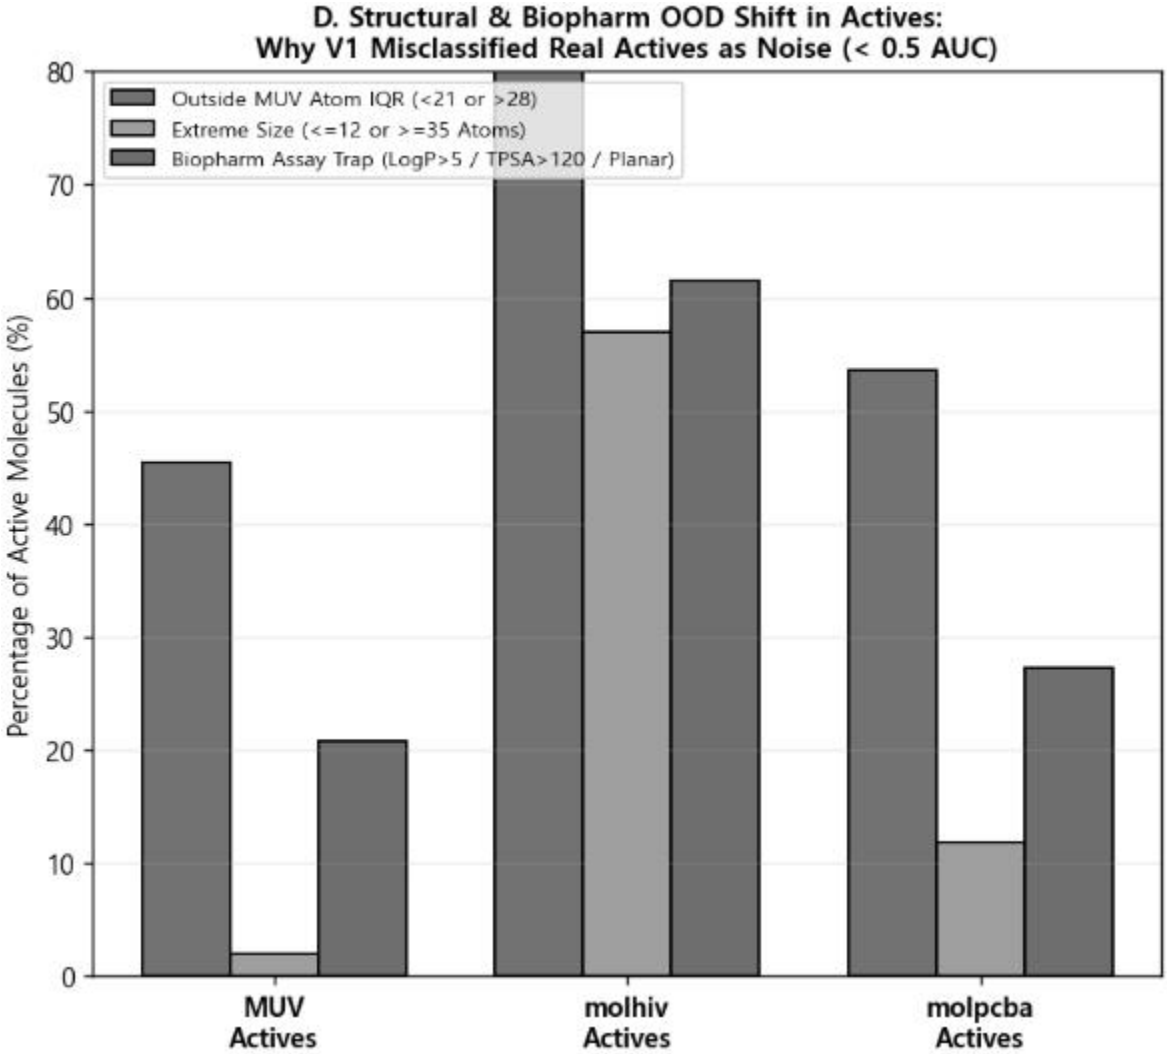
중원자 수 MUV 벤치마크는 21~28 IQR분포합니다. molhiv와 molpcba는 MUV를 벗어난 정도가 각각 81.5%, 53.6%입니다. 대체로 MUV Greenhouse 영역은 전체 분자 분포에서 Small Fragment에 모여있음을 알 수 있습니다.



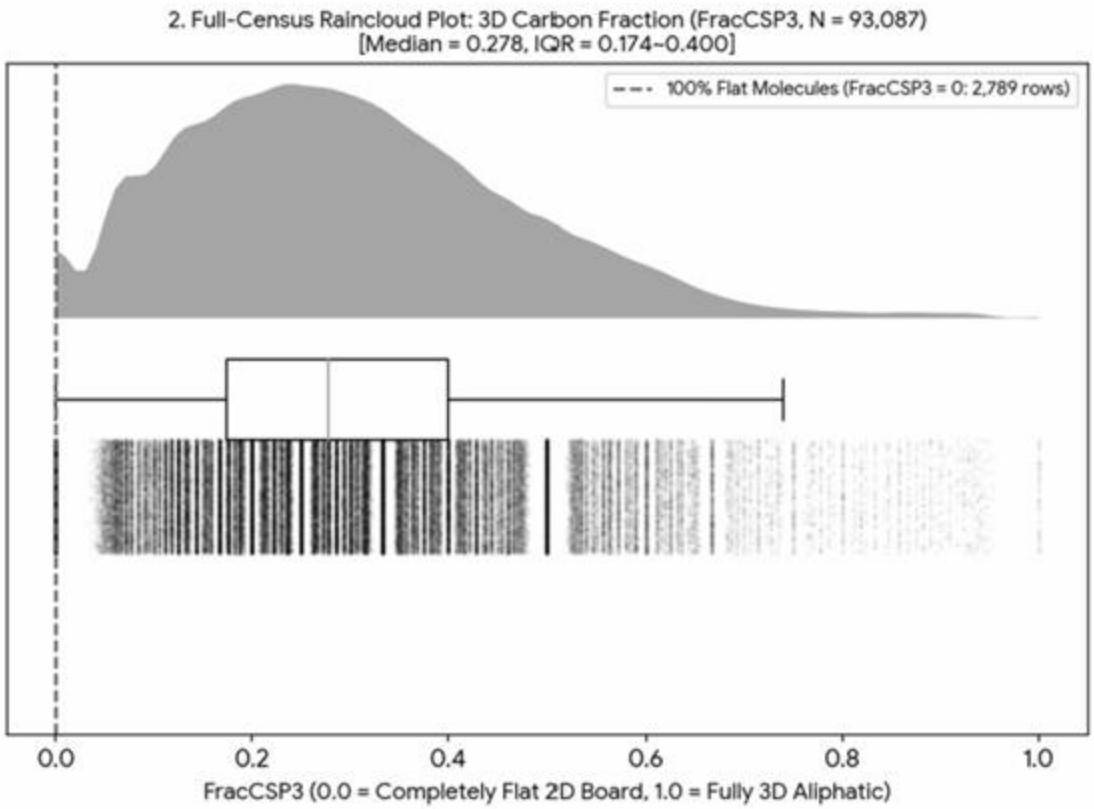
MUV Original은 활성 1개당 비활성이 510개이므로 비활성 디코이가 전체의 99.80% 100 - 0.20를 차지합니다. (V2에서는 전체 테스트셋을 만들 때, MUV의 비율을 조정했습니다. 비활성을 510개 수준에서 137개 수준으로 줄여서 활성 분자가 차지하는 지분이 0.20%에서 약 3.6배 늘어난 0.73%로 표기가 되었습니다.) ogbg-molpcba는 Scaffold Test셋 내 활성 샘플 5개 이상인 126개 태스크에서 활성 비율이 2.56%입니다. ogba-molhiv는 Scaffold Test셋 내부의 활성 분자 수 / 전체 테스트 분자 수에서 3.16%의 활성 비율이 나타납니다.



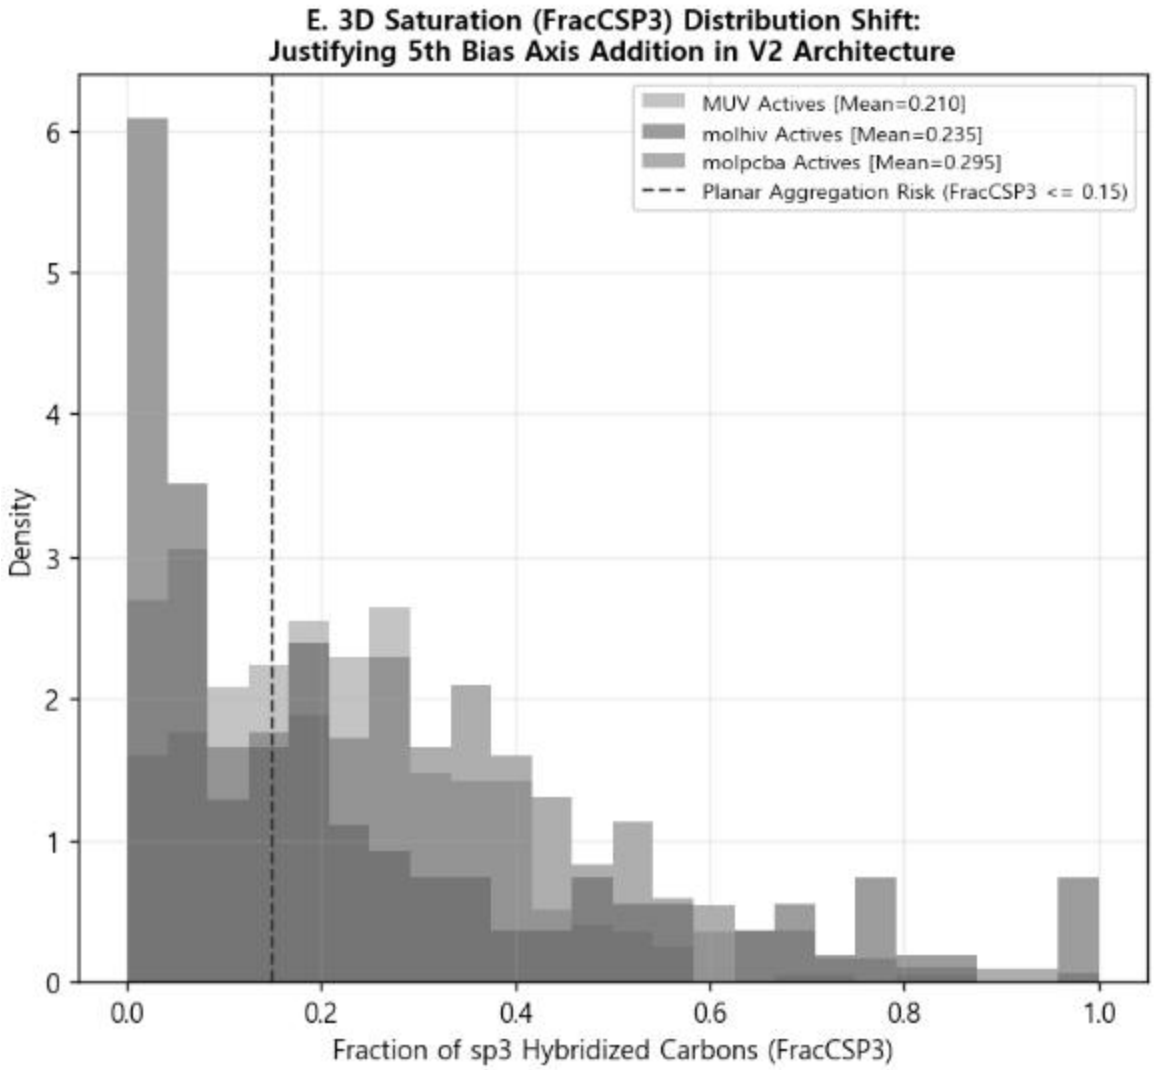
x축은 분자의 크기와 무게를 나타내는 지표로 100 ~ 900 Da 범위가 표시되어 있습니다. 우측으로 갈수록 분자의 크기가 크고 무거운 거대 분자입니다. y축은 분자가 기름(옥탄올)과 물에 녹아드는 비율을 로그로 환산한 지표(Crippen 방식 계산 LogP)로, - 4 ~ 10 범위가 표시되어 있습니다. 위로 갈수록 지용성이 극단적으로 높아 물에잘 녹지 않고 비특이적 결합이나 응집을 일으키기 쉬운 분자입니다. 기준선 2개는 각각 리핀스키 5법칙 하의 분자량 상한선인 500 Da 기준선과 지용성 함정의 임계값인 LogP = 5.0 기준선입니다. 기준선을 넘으면 분자가 너무 거대하거나, 가짜 활성(비특이적 흡착, PAINS 성향)을 유발할 위험이 매우 높습니다. MUV 데이터는 기준선 내부에 잘 모이며 molpcba도 해당 영역을 포함하여 주변으로 더 넓게 퍼져 있습니다. molhiv의 활성 분자는 양의 상관성을 미세하게 보이며 우상향 화학공간을 보입니다. 이럴 경우 분포 밖으로 넘어가는 비정상 규격외(Out-of-Distribution)이 나타나며 극단적 지용성이 나타난 분자는 물 기반의 시험관 용액 안에서 단백질의 정상 결합 부위가 아니라, 단백질 표면의 기름기 있는 부위에 무차별적으로 붙거나 콜로이드를 만듭니다. 이것은 약효가 난 활성으로 분류할 수 없지만, 실험 장비에선 기름 활성으로 나타납니다.



각 데이터셋 중 가장 우측에 있는 막대는 지용성 뿐만 아니라 극성 표면적, 분자의 입체 평면성을 복합 조건으로 묶어서 활성 분자의 생약학적 함정 조건에 걸린 정도를 나타냅니다. 거대한 극성 표면적(TPSA > 120)의 경우 전하를 띠는 원자단 면적이 지나치게 넓은 분자는 단백질이나 시험관 표면, 측정용 형광 염료 등과 무차별적인 수소 결합을 맺으며 반응 용액의 전기적/광학적 성질을 왜곡합니다. 그 결과 측정 장비가 읽는 형광이나 빛 신호를 교란해 마치 표적 반응이 일어난 것처럼 착시를 일으킵니다. 벤젠 고리 등이 넓게 펼쳐진 평평한 분자는 DNA 이중나선 틈새나 단백질 주름 사이에 무작위로 들어가거나 판판하게 겹쳐 침전물을 형성합니다. 이는 약효가 아닌 광학 센서 간섭을 유발하여 가짜 신호를 만듭니다. MUV에도 볼 수 있는 눈여겨볼 현상입니다.

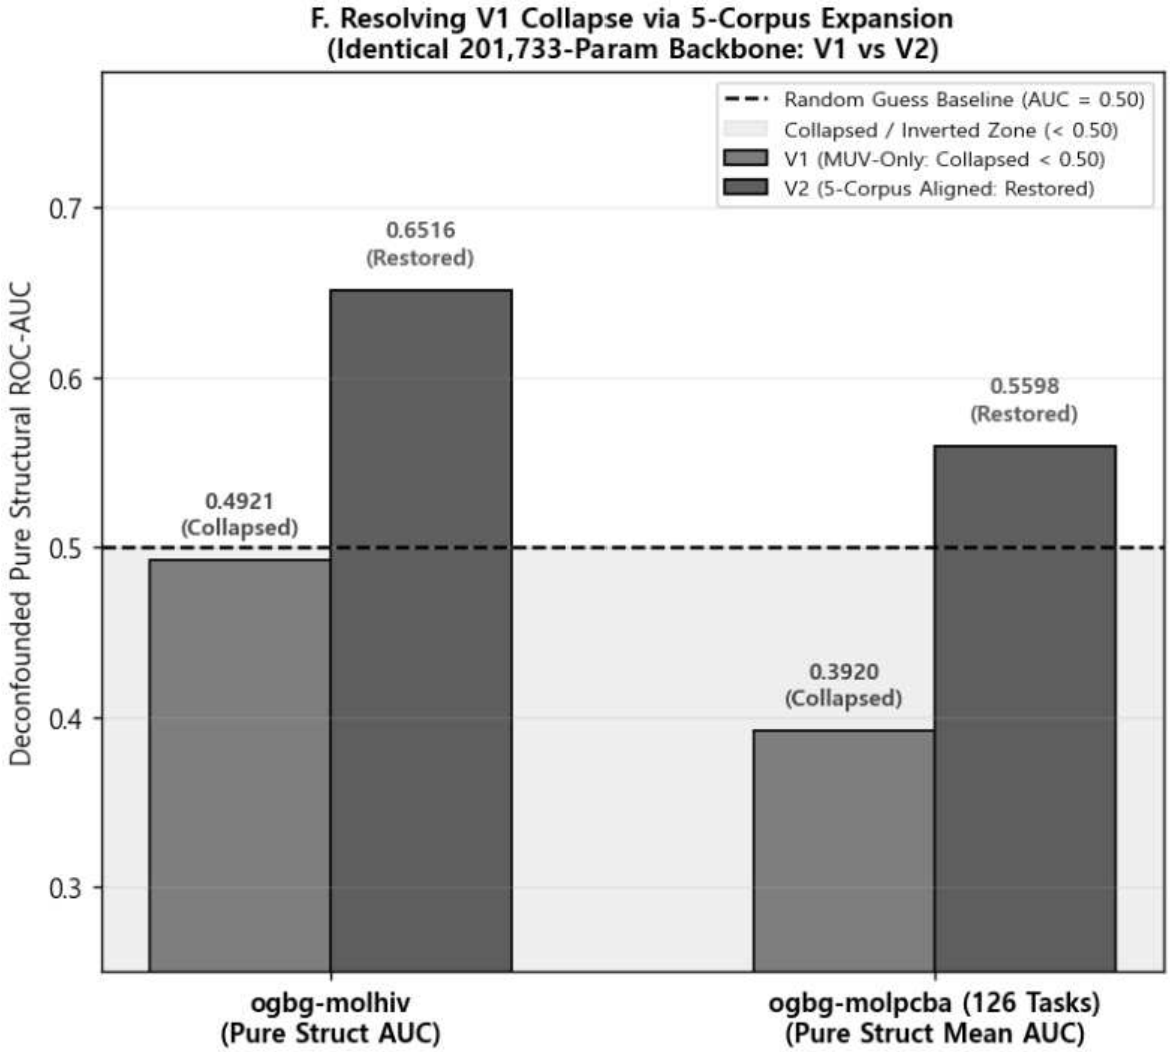


위 레인 클라우드 플롯에선 FracCSP^3를 기준으로 분자 내 탄소를 측정하고 있습니다. 0.0에서 0.1 구간에 펼쳐지고 있습니다. 0.0구간은 분자 내 모든 탄소가 SP^2 또는 sp결합(벤젠 고리, 이중 결합 등)으로만 이루어진 평평한 형태입니다. 유기합성에서 방향족 고리끼리 이어 붙이는 반응은 연구실에서 가장 성공 확률이 높고 만들기 쉽습니다. 따라서 흔히 화학 라이브러리에는 이 영역에 분자가 쌓이는 모습이 관찰됩니다. 이들은 π-π Stacking 상호작용으로 넓은 면적으로 붙습니다. 격자 결합 에너지가 너무 단단해져 물분자가 비집고 들어가지 못하므로 수용액에서 녹지 않고 뭉쳐서 침전물(Aggregate)을 형성합니다. 이들은 용액을 탁하게 하여 빛을 산란시켜 광학 측정 장비가 표적 단백질과 강한 반응을 일으켜서 신호가 억제되었다고 판단하는 생약학적 함정으로 이어집니다. 또한 전체 분자 절반 이상이 0.278근처에 분포하는 낮은 입체성을 띕니다.



FracCSP3는 꼭 보정을 해야 하는 편향 축(Bias Axis)일 수 밖에 없습니다. MUV를 넘어서 molhiv와 molpcba를 함께 비교하는 경우 0.15이하의 극단적 평면성이 나타나는 구간은 분자 간 π-π Stacking으로 물에 녹지 않고 분자끼리 엉켜 붙는 위양성 고위험 영역입니다. molhiv데이터셋의 경우 0.0에서 0.05구간 막대의 밀도가 6.0을 뚫고 올라갑니다.
molhiv의 active판정이 붙은 화합물 중 대부분이 정교한 바인딩 포켓 결합 물질이 아니라 판판한 판자 구조 때문에 뭉쳐 수용액을 뿌옇게 만들어 집계된 침전성 잡음이였음을 보여줍니다.

따라서 이러한 정보를 바탕으로 데이터셋을 추가 비율 조정 후 구성하고, 아키텍쳐를 조정한 결과



molhiv를 추론할 때 0.5언더로 나타난 붕괴된 모델에 비하여 향후 개선 과정 V2에서 완성된 모델은 0.6516 AUC가 나타나며 molpcba의 경우에도 기준점을 넘겼습니다.
V1의 추론 성능을 아키텍쳐의 변경을 직접 가하기 전 올려보기 위하여 데이터셋을 모아서 늘렸습니다. 추가 코퍼스는 Tox21, SIDER, BBBP, ColinTox입니다.

[표 1] V1 단일 코퍼스 vs V2 5대 혼합 코퍼스(37,769건, 59채널, 유효라벨 188,666개) 정밀 수량 및 보완 특성 요약표

	코퍼스 구분	분자 수 (점유율)	채널 수	유효 라벨 수 (점유율)	활성(Active) / 비활성(Inactive)	활성:비활성 비율 (기저율)	양성 신호 기여도	원자수 중앙값 (≤12 / ≥35 비율)	트랩 경계군 / FracCSP3 평균
0	[대조군 V1] MUV 원본 전체	93,087건 (-)	17ch	249,886개 (-)	489 / 249,397	1 : 510.0 (0.20%)	-	24 (0.4% / 1.9%)	10.8% / 0.298
1	[V2 구성] MUV	25,000건 (66.2%)	17ch	67,274개 (35.7%)	489 / 66,785	1 : 136.57 (0.73%)	1.56%	24 (0.4% / 1.9%)	10.8% / 0.298
2	[V2 구성] Tox21	7,823건 (20.7%)	12ch	77,864개 (41.3%)	5,858 / 72,006	1 : 12.29 (7.52%)	18.73%	16 (33.3% / 6.4%)	18.6% / 0.459
3	[V2 구성] SIDER	1,427건 (3.8%)	27ch	38,529개 (20.4%)	21,868 / 16,661	1 : 0.76 (56.76%)	69.93%	25 (12.7% / 20.5%)	34.5% / 0.461
4	[V2 구성] BBBP	2,039건 (5.4%)	1ch	2,039개 (1.1%)	1,560 / 479	1 : 0.31 (76.51%)	4.99%	23 (8.8% / 9.4%)	18.3% / 0.462
5	[V2 구성] ClinTox	1,480건 (3.9%)	2ch	2,960개 (1.6%)	1,498 / 1,462	1 : 0.98 (50.61%)	4.79%	23 (11.4% / 16.6%)	28.6% / 0.466
6	[실험군 V2] 5대 통합 코퍼스 합계	37,769건 (100.0%)	59ch	188,666개 (100.0%)	31,273 (16.58%) / 157,393 (83.42%)	1 : 5.03 (16.58%)	100.00%	23 (8.6% / 4.5%)	14.4% / 0.353

1. [5대 코퍼스 블록 대각 혼합 산식 (Block-Diagonal Multi-Corpus Aggregation)]
   - 총 분자 수 (N_total) = N_MUV(25,000) + N_Tox21(7,823) + N_SIDER(1,427) + N_BBBP(2,039) + N_ClinTox(1,480) = 37,769건
   - 총 채널 수 (T_total) = 17 + 12 + 27 + 1 + 2 = 59개 채널
   - 총 유효 라벨 (V_total) = 67,274 + 77,864 + 38,529 + 2,039 + 2,960 = 188,666개
     * 전체 양성(Active) 라벨 = 31,273개 (16.58%) [이 중 SIDER(21,868개) + BBBP(1,560개) + ClinTox(1,498개) = 24,926개 (79.71%)]
     * 전체 비활성(Inactive) 라벨 = 157,393개 (83.42%) [활성 : 비활성 종합 비율 = 1 : 5.03]

5대 통합 코퍼스는 총 분자 수 37,769건, 59개 채널, 유효 라벨 188,666개로 구성되며 전체 활성(Active) 라벨 31,273개(16.58%)대 비활성라벨 157,393개(83.42%)로 종합 활성:비활성 비율이 1:5.03에 맞춰졌습니다.

분자 수의 66.2%(25,000건)을 차지하는 기저 코퍼스 MUV의 양성 신호 기여도는 1.56%(489개)에 불과한 반면, 분자 수 합계가 13.1%(4,946건)인 SIDER(69.93%)/BBBP(4.99%)/ClinTox(4.79%)3개 유입 코퍼스가 전체 양성 라벨의 79.71%(24,926개)를 공급합니다.

활성:비활성 비율(기저율 차이 0.73% ~ 76.51%, 105.25배 격차)로 인해 평균 목표 로짓 절편(모집단 평균 μk = ln(Pk / 1 - Pk))이 MUV(-4.9181)에서 BBBP(+1.1807)까지 평균 변화량 = 6.0989만큼 벌어집니다.

이 값은 확률(Probability)개념을 실수 전체의 연속적인 공간으로 매칭하는 로짓(Logit)변환, 로그 오즈(Log-odds)의 이론적 배경과 연결이 되어 있습니다. 통계와 머신러닝에서 오즈(Odds)는 '실패할 확률(나머지)에 비해 성공할 확률이 얼마나 더 높은가'를 나타내는 비율을 의미하며, 공식은 어떤 사건이 일어날 확률 P에 전체에서 그 사건이 일어날 확률을 뺀 나머지 확률(여집합)을 나눈 형태로 일어날 확률과 일어나지 않을 나머지의 확률의 상대적인 가능성을 의미합니다. 일어날 확률이 더 크면 양수가 나옵니다. 이 오즈 값에 자연로그를 씌운 로그 오즈(Log-odds)를 취하면 비율의 비대칭성을 대칭적인 실수 공간으로 펼쳐주기 때문에 0.5는 -무한대에서 +무한대의 공간의 정 가운데인 0에 배치가 됩니다. 0.5보다 높은 확률은 양수가 되고, 0.5보다 낮은 확률은 음수가 됩니다. 성공 확률이 0.73%인 매우 낮은 경우 0근처에 뭉쳐있던 확률이 왼쪽으로 당겨지며 -4.92라는 거대한 음수 값이 됩니다. Tox21은 가능성 7.52%로 -2.65, ClinTox는 가능성 50.61%로 +0.09, SIDER은 56.76%로 +0.26, BBBP는 76.51%로 +1.18 값이 됩니다. 모델은 데이터를 분석하기 전에 기본 출발선(보통 흔히 생각하는 0,0)을 둡니다. 정상적인 활성 물질을 찾기 쉬운 경우 모델의 출발 선은 위쪽 양수에 이지만, MUV와 같은 비활성이 극도로 많고 활성이 1%도 안되는 데이터 셋에서는 모델은 일단 어떤 feature을 보지도 않은 상태여도, 이 데이터는 원래 성공하기 거의 불가능 곳이라며 기본 점수를 음수 값에 꾹 눌러두고 시작합니다. 이를 '출력층의 초기 편향(Bias)또는 절편(Intercept)은 학습 데이터셋의

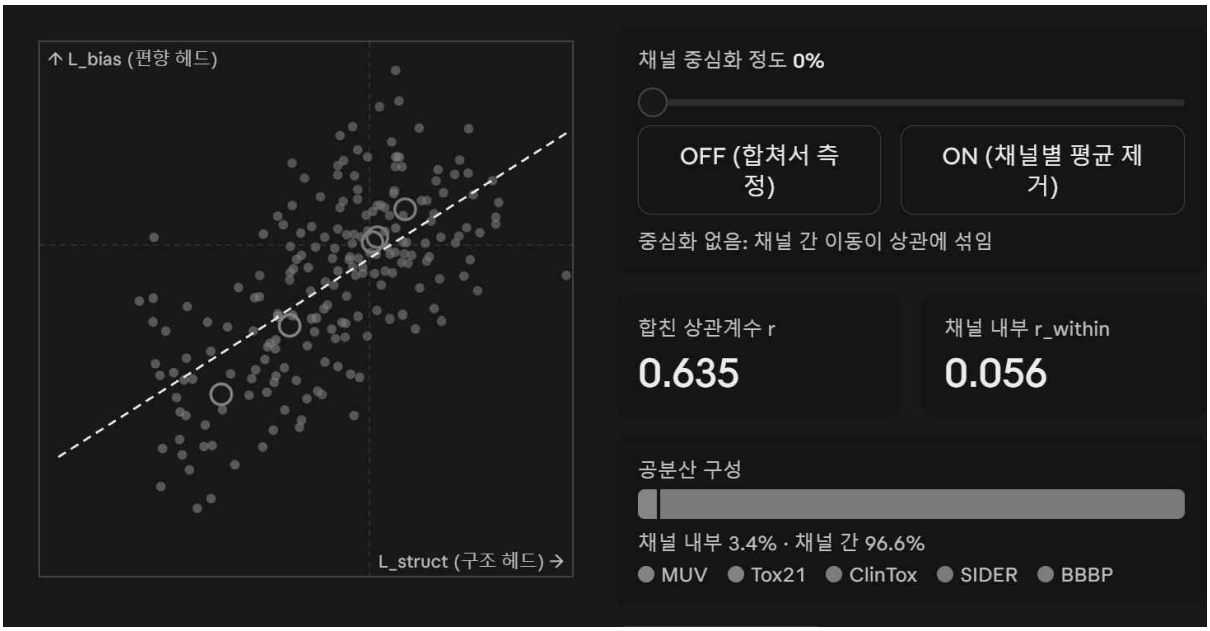
기저율(Base rate/Prevalence)을 반영한다’라고 합니다. 이 원천적인 클래스의 불균형의 정도를 로짓 공간상의 좌표로 환산했을 때 나타나는 사전 확률(Prior probability)의 기하학적 위치를 확인할 수 있습니다.



2. [코퍼스별 기저율(P_k) 차이에 의한 목표 로짓 절편(Target Log-Odds Intercept, μ_k = ln(P_k / (1 - P_k))) 격차]
   - MUV (17ch, P = 0.73%) -> 평균 목표 로짓 절편 μ_MUV = -4.9181 (강한 음수 절편)
   - Tox21 (12ch, P = 7.52%) -> 평균 목표 로짓 절편 μ_Tox21 = -2.6503 (중간 음수 절편)
   - ClinTox (2ch, P = 50.61%) -> 평균 목표 로짓 절편 μ_ClinTox = +0.0941 (중립 절편)
   - SIDER (27ch, P = 56.76%) -> 평균 목표 로짓 절편 μ_SIDER = +0.2571 (양수 절편)
   - BBBP (1ch, P = 76.51%) -> 평균 목표 로짓 절편 μ_BBBP = +1.1807 (강한 양수 절편)
   => 코퍼스 간 기저율 최대 격차 = 76.51% ÷ 0.73% = 105.25배 (로짓 절편 이동폭 Δμ = 6.0989)

3. [심슨의 역설(Simpson's Paradox) 수리적 증명 – 전공분산 법칙 (Law of Total Covariance)]
   가산형 양갈래 모델(L_total,i,t = L_struct,i,t + L_bias,i,t)에서 채널별 목표 절편 μ_t가 두 헤드에 분담(μ_S,t, μ_B,t)될 때, 59개 채널을 단순 평탄화(Uncentered)하여 측정한 전체 공분산 Cov_total(L_struct, L_bias)은 다음과 같이 분해됩니다:

$$\begin{aligned}\mathrm{Cov}_{total}(L_{struct}, L_{bias}) &= E_t[\,\mathrm{Cov}_{within}(L_{struct,t}, L_{bias,t})\,] + \mathrm{Cov}_{between}(\mu_{S,t}, \mu_{B,t}) \\ &= (\text{채널 내부 순수 공분산: } 0.0402) + (\text{채널 간 기저율 절편 공분산: } 1.1444) \\ &= 1.1847\end{aligned}$$



해당 산점도를 보면 코퍼스 별로 산점도의 점이 무리를 지어있습니다. 앞서 Y절편에 나열된 순서대로 좌측부터 배치가 되어있습니다. MUV는 기저율이 낮아 점선 아래의 음수 영역에 있고, BBBP나 SIDER은 양성 기저율이 높아 오른쪽 양수 영역에 있습니다.

데이터를 코퍼스 별로 나누지 않고 통째로 합쳐서 계산하는 경우 전체 공분산과 상관계수는 채널 내부의 공분산과 그룹 평균 간의 공분산의 합으로 쪼개집니다. 이에 따라 상관계수를 구하는 공식은 방향성을 나타내는 공분산을 개별 분산의 기하 평균으로 나누어 0에서 1사이 값으로 정규화 한 값이며, 두 변수가 자신의 평균에서 벗어나는 방향과 패턴이 얼마나 닮았는지 유사도(코사인 유사도)를 확인할 수 있습니다.

이 상관계수를 기하학(벡터의 각도)와 정보량(분산의 공유)관점으로 나누어서 풀어쓴다면, 데이터 샘플이 n개 있다면 변수 x와 y는 2차원 평면의 점 n개로 볼 수도 있지만, n차원으로 확대가 되면 2개의 방향성을 가진 화살표(벡터)로 볼 수도 있습니다. 편차 벡터를 만들면, 절대적인 수치를 버리고 순수한 변동만 확인할 수 있으며 제곱을 하지 않으면 합은 0이 되는 원점에서 뻗어가는 순수한 변동 화살표가 됩니다.

선형대수학에선 두 벡터 u, v사이의 각도를 세타라고 할 때 코사인 유사도 공식으로 확인할 수 있습니다. 백터 간의 유사도 즉 성분 간의 곱(내적)에 자유도를 나누어주는 것은 통계학의 방식에 연관을 지을 수 있습니다. 공분산을 계산할 땐, 편차끼리 곱한 것을 다 더한 후 표본 자유도로 나누어 평균적인 동반 변동을 구할 수 있습니다. 내적도 요소 간 곱을 다 더하는 방식이며 따라서 공분산의 분모 n-1에 자유도를 곱해주면 내적값이 나옵니다. 내적이란 두 화살표가 얼마나 같은 방향으로 뻗어있는가를 곱해서 누적한 값입니다. 평균이라는 기준보다 높으면 + * + = +가 나오고 기준보다 낮으면 - * - = +가 되어 내적의 값은 커집니다. 공분산의 경우도 방향을 측정합니다. 둘의 동작은 결국 같습니다. 이것을 코사인 유사도 공식에서는 분자로 넣을 수 있습니다.

통계학에서는 n - 1을 자유도라고 부릅니다. 우리가 가진 데이터는 세상의 모든 분자나 사람을 다 모은 것이 아니라 그중 일부를 뽑아온 표본입니다. 샘플을 가지고 편차를 계산할 땐 전체의 모평균을 알 수 없기 때문에 표본 평균을 사용합니다. 수학적 제약이 있습니다. 모든 데이터에서 표본 평균을 뺀 편차들은 다 더하면 무조건 0이 된다는 것입니다. 만약 데이터가 n = 3개라면 첫 번째 편차가 +2, 두 번째 편차가 -1이라면 세 번째 편차는 무조건 -1이어야 0이 됩니다. 따라서 데이터 3개가 있어도 자유롭게 움직일 수 있는 값은 3개 중 두 개일 뿐이고 마지막 하나는 평균에 묶여서 자동으로 결정이 됩니다. 표본 평균은 애초에 표본끼리 뭉쳐진 값이기 때문에 모평균보다 더 가깝게 모여 있습니다. 따라서 편차의 제곱이나 내적의 합이 모집단의 변동폭보다 아무리 곱이라고 하더라도 좀 작게 나옵니다.

이 값을 분모 n으로 나누면 안 그래도 작은 값을 더 작게 만들어버리기 때문에 분모를 조금 더 작게 보정을 해줍니다. 이 때, 보정에 쓰는 수가 자유도이며, 이러한 방식을 베셀 보정(Bessel's Correction)이라고 부릅니다.(평균을 낼 때 이미 값 하나가 고정되어 자유를 사용했기 때문에 스케일링을 해줍니다.)

방향을 찾고 나면 화살표의 길이를 확인합니다. 2차원 평면에서는 원점 (0, 0)에서 어느 점까지 이어진 화살표(벡터)의 길이를 잴 때는 피타고라스의 정리를 사용합니다. 각 요소는 편차의 제곱과 같고 가중합하여 루트를 씌우면 거리를 확인할 수 있으며 이를 유클리드 거리라고 합니다.

편차는 평균에 가까우면 평균 언저리 0에서 짧은 화살표 길이를 가집니다. 점수가 멋대로 날뛰어 편차가 크면 화살표 길이는 매우 길어집니다. 데이터가 가진 변동의 총 에너지를 빗변의 길이로 잽니다. n개의 데이터의 에너지를 자유도로 나누어 데이터 1개 당 평균적으로 얼마나 출렁이는지를 확인하기 위한 스케일링을 진행하면 표준편차가 나옵니다. 이 식의 분모에 해당하는 자유도에 씌운 루트를 반대로 넘겨 곱해주면 화살표의 길이는 자유도에 루트를 씌운것 * 표준편차로 정리할 수 있습니다. X변수의 화살표 길이와 Y변수의 화살표 길이를 곱하면 자유도에 루트를 씌운 값에 x변수의 표준편차와 자유도에 루트를 씌운 값에 Y변수의 표준 편차를 내적한 값을 곱한 식으로 정리가 되며, 루트가 이 때 풀리게 됩니다.

분자에도 루트가 풀린 자유도 * 공분산이 있었기 때문에 분모에 남은 자유도도 약분이 되어 사라집니다. 남는 것은 공분산 나누기 x변수의 표준편차와 y변수의 표준편차의 곱이 됩니다.

이것은 곧 상관계수와 같은 식입니다. 상관계수는 n차원 공간에서 두 변동 벡터가 이루는 x변수와 y변수의 사잇각의 코사인 값과 동일합니다.

두 화살표의 사잇각이 0도가 되면 둘은 완전히 포개져서 같은 방향을 가리킵니다. X변수가 평균보다 +2 튀면, Y도 비례하여 올라갑니다. 양의 상관관계를 얻습니다(+1에 가까워집니다.)

두 화살표가 서로 90도가 되면 직교, 상관이 없습니다. X의 변동이 Y의 방향과 아예 관련이 없습니다. 내부 상관계수(r = 0.0557은 각도가 약 86.8도)가 직각 상태에 해당합니다.

두 화살표가 서로 180도가 되면 둘은 정 반대의 방향을 가리킵니다. X가 평균보다 올라가면 T는 이와 비례하게 평균 아래로 떨어집니다. 음의 상관관계를 가집니다.

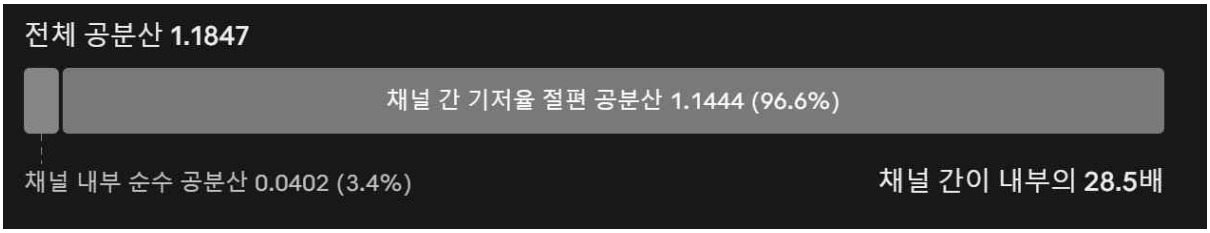
통계 모델에서 결정계수 R의 제곱은 설명력이라고 합니다. X를 가지고 Y를 선형회귀한다는 것은 벡터가 놓인 직선 위에서 코사인 값을 구하는 것과 같으며, 이때 그림자의 길이 비율은 원의 반지름이 r과 같습니다. 이때 분산의 단위로 바꾸며 제곱을 취하면 단위가 면적으로 바꾸는 것과 같은데, 이 때 제곱합의 비율은 R의 제곱이 됩니다.

내부 설명계수가 0.5라면 Y변수의 혼자 흔들리는 전체 변동(총분산)을 100%로 둘 때 r의 제곱은 0.5의 제곱과 같으며 0.25 즉, 25%와 같습니다. Y가 움직이는 전체 이유 중 25%는 X도 함께 움직이기 때문에 일어난 것이고, 나머지 나머지 75%는 X와 무관한 Y만의 잡음이라는 의미입니다.

$$r_{total} = \frac{Cov_{within} + Cov_{between}}{\sqrt{Var_{total}(X) \cdot Var_{total}(Y)}}$$

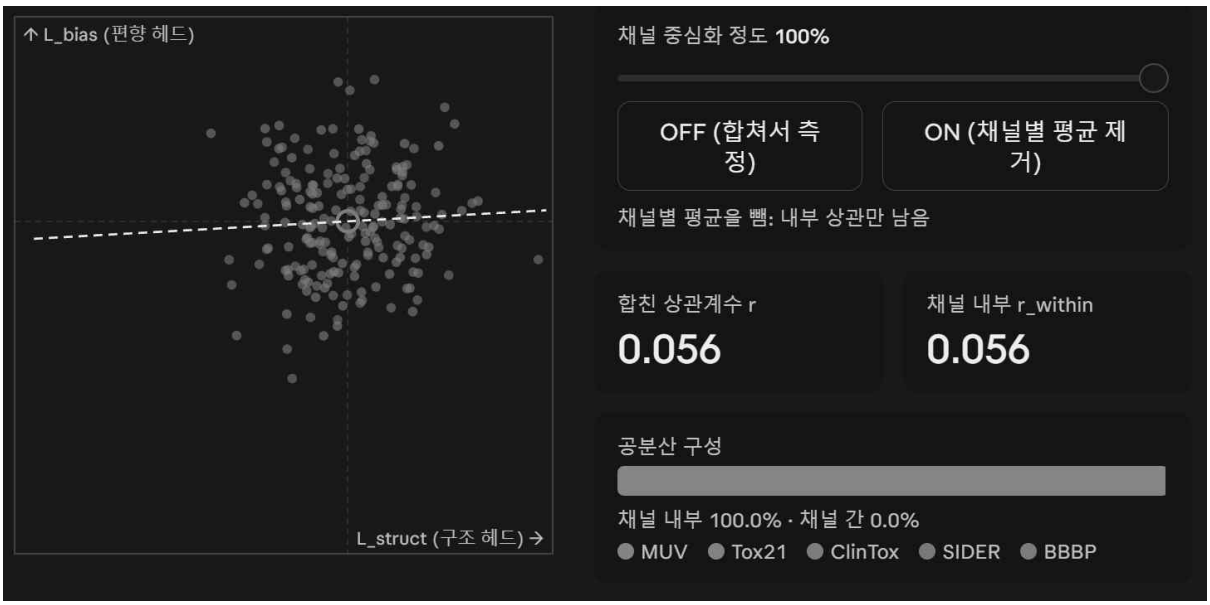
전체 공분산은 전체 데이터를 그룹 구분 없이 통째로 모아서 계산한 두 변수 간의 공분산을 말합니다. 내부 공분산은 각 태스크(채널)안에서 순수하게 두 변수가 같이 움직이는 정도(진짜 관계)를 의미합니다. 사이 공분산은 태스크(채널)별 평균값(기저율, 절편)들이 달라서 생기는 공분산입니다.

$$Cov_{total} = Cov_{within} + Cov_{between}$$



채널 내부의 순수 공분산은 0.0402로 전체의 3.4%입니다. 내부의 순수한 공분산은 0.0402이며 각 채널 내부만 따로 떼어놓고 보면 상관계수가 0.0557(반올림 시 0.056) 즉, 0에 가깝습니다. 이것은 상관성이 없는 직교 상태를 의미합니다.

채널 간 절편 공분산은 1.1444로 전체의 96.6%입니다. 채널들 사이의 평균값(절편, 기저율의 차이 때문에 생긴 공분산은 1.1444로 양의 상관관계를 크게 보여줍니다. 순수 공분산(0.0402)의 28.5배에 달하며, 전체 공분산(1.1847 = 0.0402 + 1.1444)의 96.6를 사이 공분산이 차지하고 있었습니다. 즉 데이터 전체에 찍힌 공분산의 대부분은 실제 분자 구조를 읽어서 나온 상관성이 아니라 채널 평균의 높낮이가 달라서 생긴 집단간 위치 차이가 남은 것입니다. 보정 없이 합친 평탄화 상관계수는 내부 상관성이 0.05밖에 되지 않는데 평균이 끌어올린 것이 r = 0.6346만큼 이론적으로 나올 수 있고, 모델의 학습 epoch 6에선 r =0.4933이라는 높은 상관계수가 나타납니다. 이것을 학습을 잘 하여 찾아낸 것으로 착각할 수 있지만 사실은 클래스 별 차이가 올린 수치입니다.



이 글을 준비하며, 아키텍처에서 오차 함수 내 직교 페널티를 계산하는 과정의 임시 중심화가 존재하지만, 아키텍처 내부의 구조적 채널 중심화(출력 직전 채널별 평균을 강제로 차감)와 타깃 기저율 절편의 사전 분리 과정(순수 편차만 학습)이 빠졌음을 확인하였습니다.

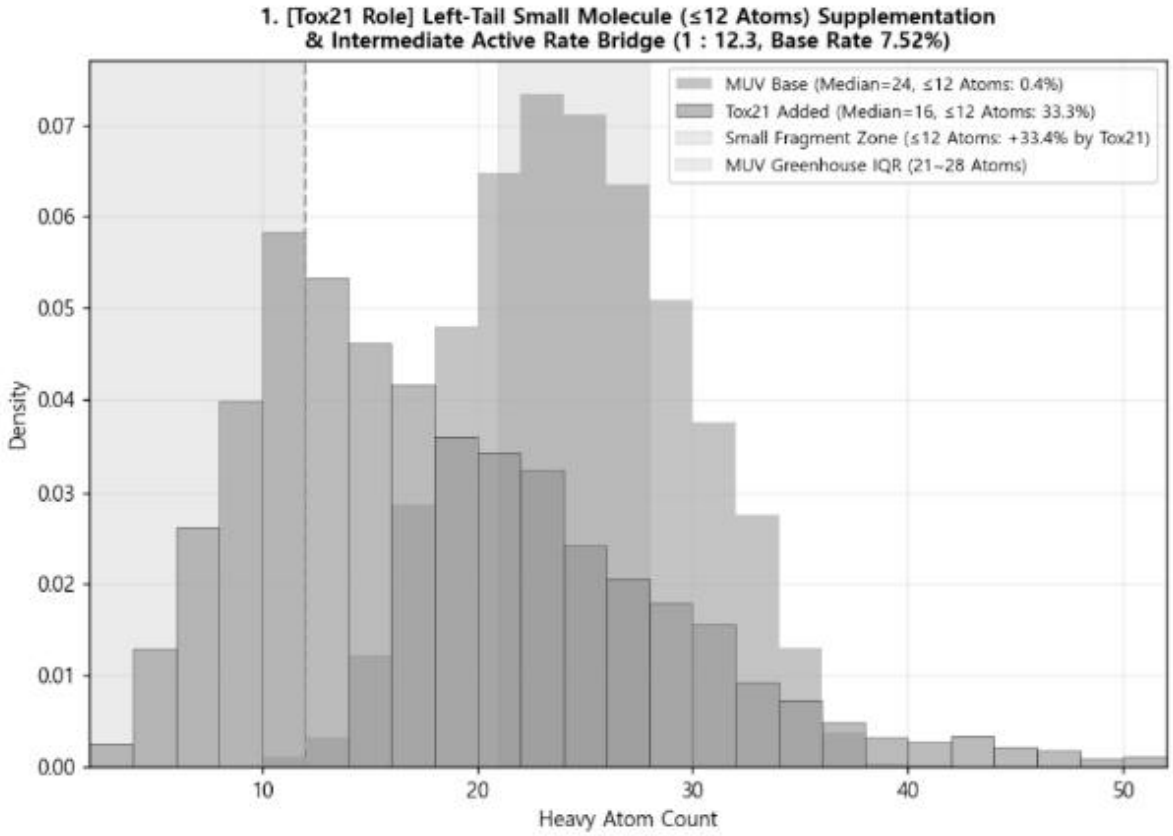
기존 직교 페널티를 계산할 때, 잠시 평균을 빼고 메인 손실에선 중심화가 안된 상태로 넣어 절편 분담이 그대로 남았습니다.

우리의 방법론은 일단 이 시점에서 해당 문제를 수용하고, 실험의 재현성을 충족하는 가중치 유지, 아키텍처 유지, 데이터셋 유지 상태로 실험을 유지하며, 해당 화학 공간에서 거리를 잴 땐, 단순 유클리드 거리가 아니라 채널 중심화 및 표준편차 정규화(Z-score)을

거친 각도의 거리(코사인 유사도)를 사용하며 이는 통계학적으로는 마할라노비스 거리가 해결하려는 공분산 왜곡을 신경망 학습 과정에서 직접 대각화 하여 해결하는 방식으로 설정이 되어 있습니다.(각 채널 표준 편차로 나누는 과정은 공분산 행렬을 대각 원소로 나누는 과정과 보정의 결이 유사합니다. 하지만 코사인 유사도는 직접 r을 추출한다면 마할라노비스는 역공분산 행렬을 곱하여 상관성을 보정하는 과정에 해당합니다. 하지만 결은 유사합니다. 핵심은 상관성을 고려한 공간 축 스케일링을 고려하여 유클리드 거리로 단순히 다루지 않는다는 의미입니다. 이를 실험을 통해 증명한다면 더욱 발전적일 것이라고 생각합니다.)

이에 따라 결론적으로 소량 투입된 SIDER와 BBBP의 높은 양성 기저율이 절편 공분산이 전체의 상관계수를 올립니다. 심슨의 역설은 부호의 역전을 의미하는 용어이므로, 집단 교란이 일어난다고 정정합니다. 이것이 집단 교란의 원인으로 사료됩니다.

따라서 채널 내부에서 구조와 편향이 거의 직교(r_within = 0.0557)하더라도, 채널 중심화를 생략하면:
r_uncentered = Cov_total / (Std_total(L_struct) × Std_total(L_bias))
= 1.1847 / (1.3664 × 1.3664) = 0.6346 (실제 Epoch 6 관측치: r = 0.4933)
=> 즉, 소량 투입된 SIDER·BBBP의 높은 양성 기저율이 만든 절편 공분산(1.1444)이 직교성을 붕괴시킨 주원인임이 증명됩니다.

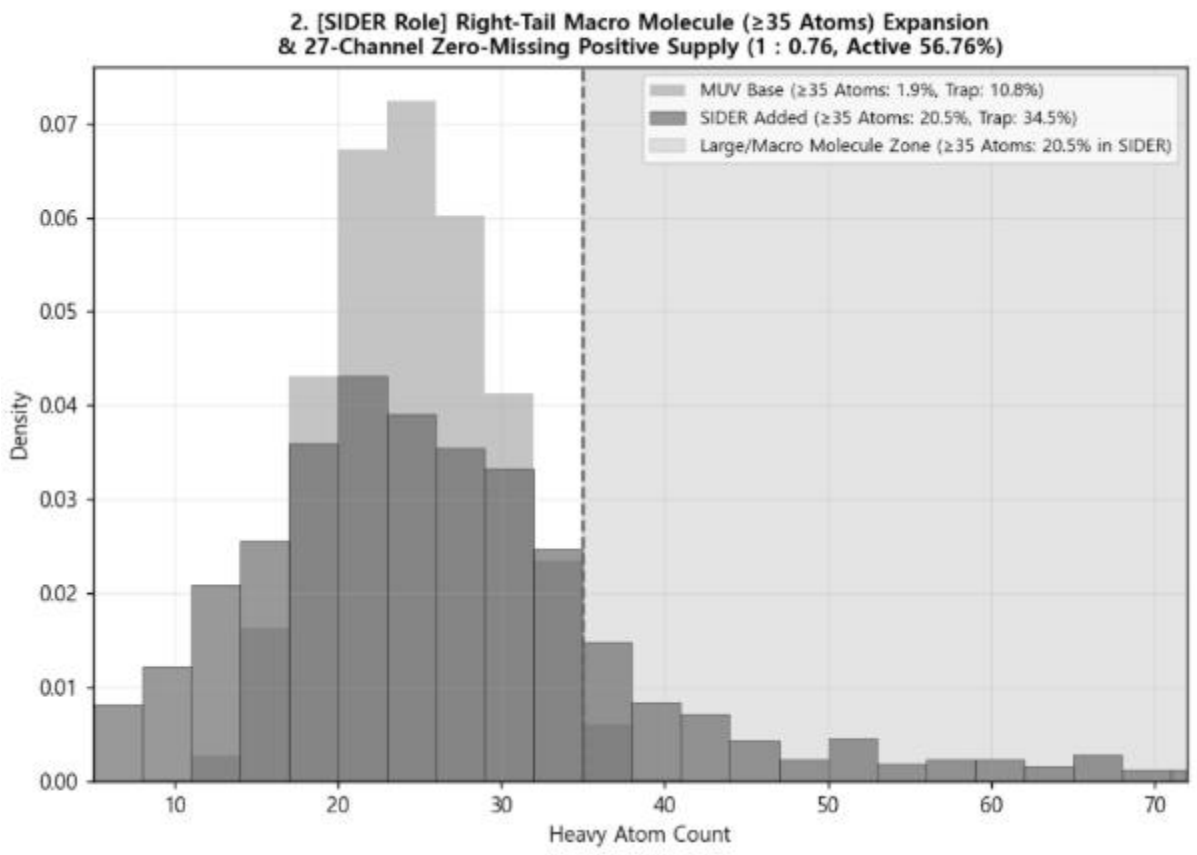


MUV데이터는 중원자 수 24의 중앙값을 가지고 있으며 21에서 28개 구간에 누적되어있습니다. 이는 대부분의 분자가 IQR에 집중된 인위적으로 통제된 데이터셋입니다. Tox21은 중원자 수 16개 중앙값을 가진 분자들이 누적되어있으며 MUV보다 작고 가벼운 small molecule 위주로 구성이 되어 있습니다. affinity 여부를 떠나서 실제 화합물에는 중원자 수 12개 이하의 분자가 존재합니다. 하지만 MUV는 리핀스키 법칙에 따라 통제된 Left - tail이 비어있는 분자들로 구성이 되어 있습니다. Tox21은 12개 이하 작은 분자가 전체 데이터셋의 33.3%를 차지하여 좌측 영역에 대량으로 포진합니다.

MUV의 경우 활성 비율이 0.20%(1:510)수준으로 극단적인 비활성 편향 데이터셋입니다. Tox21은 활성 비율이 7.52%(활성 : 비활성 = 1 : 12.3)로 MUV보다 활성 라벨이 풍부합니다.

이를 통해 소형 단편 분자의 결핍을 보정할 수 있습니다. 추론 시 작은 활성 분자를 만들어도 비정상 크기 ood로 판별하지 못하는 일을 방지합니다. 이를 통해 화학 공간의 범위를 확장합니다.

이는 한편 활성 비율이 7.52%인 데이터셋을 투입하여 극단적인 저비율의 MUV와 실전 테스트셋인 ogbg-molpcba 2.56%, ogbg-molhiv 3.16%)사이의 간격 차이로 로짓이 음수로 무너지는 현상을 완화해주는 중간 가교 역할을 수행합니다.

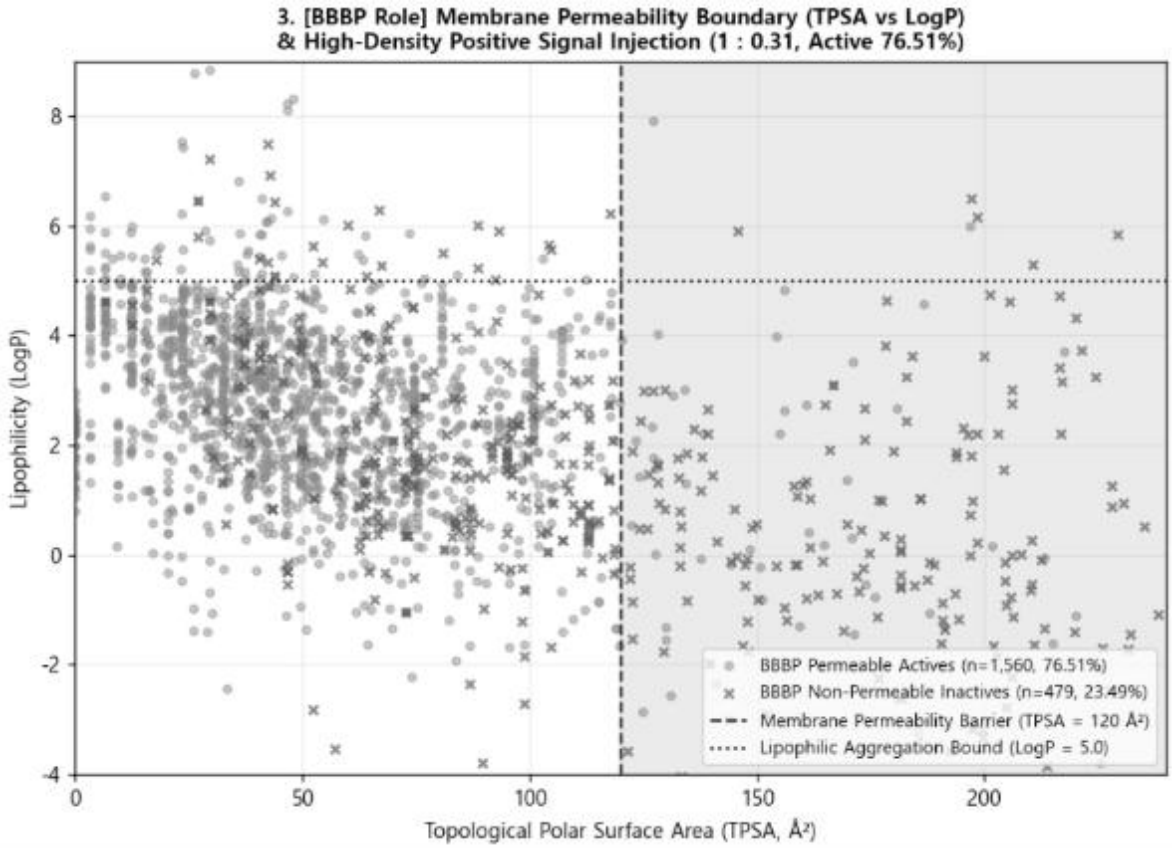


MUV는 중원자 수 35개 이상의 거대 분자 비율이 1.9%에 불과합니다. 30개 초반 수준에서 분포가 칼같이 끊겨 대형 분자 화학공간을 학습할 수 없습니다. SIDER을 공급하여 35개 이상 거대 분자 비중이 20.5%에 달하며 40~70개 이상 이르는 긴 Macro Molecule zone을 채워줍니다.

molhiv데이터셋이 특히 거대 분자 구조가 등장하는 실제 스크리닝 등 평가 셋의 예시가 되며 이 때 거대 분자 구조를 정상적인 입력으로 받아들일 수 있도록 분자 크기 스펙트럼의 상한선을 열어줍니다.

SIDER은 활성 비율이 56.76%(활성: 비활성 = 1:0.76)로 양성(Positive)샘플이 음성보다 많은 고밀도 활성 데이터셋입니다. 대부분의 멀티태스크 벤치마크는 라벨이 듬성듬성 비어있는 희소 행렬(Sprase Matrix)구조이지만 SIDER의 27개 부작용/표적 채널은 결측치가 완전히 채워져 있습니다. MUV의 극단적인 0.20% 디코이로 나타난 음수 로짓 표현 붕괴를 양수로 끌어올리는 아쳐 역할을 합니다. 이 과정까지를 통해 소형부터 대형까지 넓은 화학공간을 완성하였습니다. 비활성의 비율이 너무 높아 무조건 비활성으로 찍어 페널티를 피하던 모델이 활성 신호와 만나며 상쇄됩니다. SIDER의 거대 분자들의 디스크립터는 무겁고 기름지고 평평할수록 실험 장비에선 활성이 찍히는 경우가 많아 모델의 교란 요인이 되는 경우가 많으나, 아키텍처는 편향 축의 변수들이 예측값에 미치는 영향을 강제로 분리하여 직교화하는 구조로 만들었습니다. 이 신호들은 존재하더라도 예측에 사용할 수 없고, 타겟 단백질과 결합하는 구조적 특징만 남겨 최종 점수를 매기도록 디컨바운딩 구조로 학습하도록 설계하였습니다. 이에 따라 결합 구조만 학습할 가능성이 높은 모델은

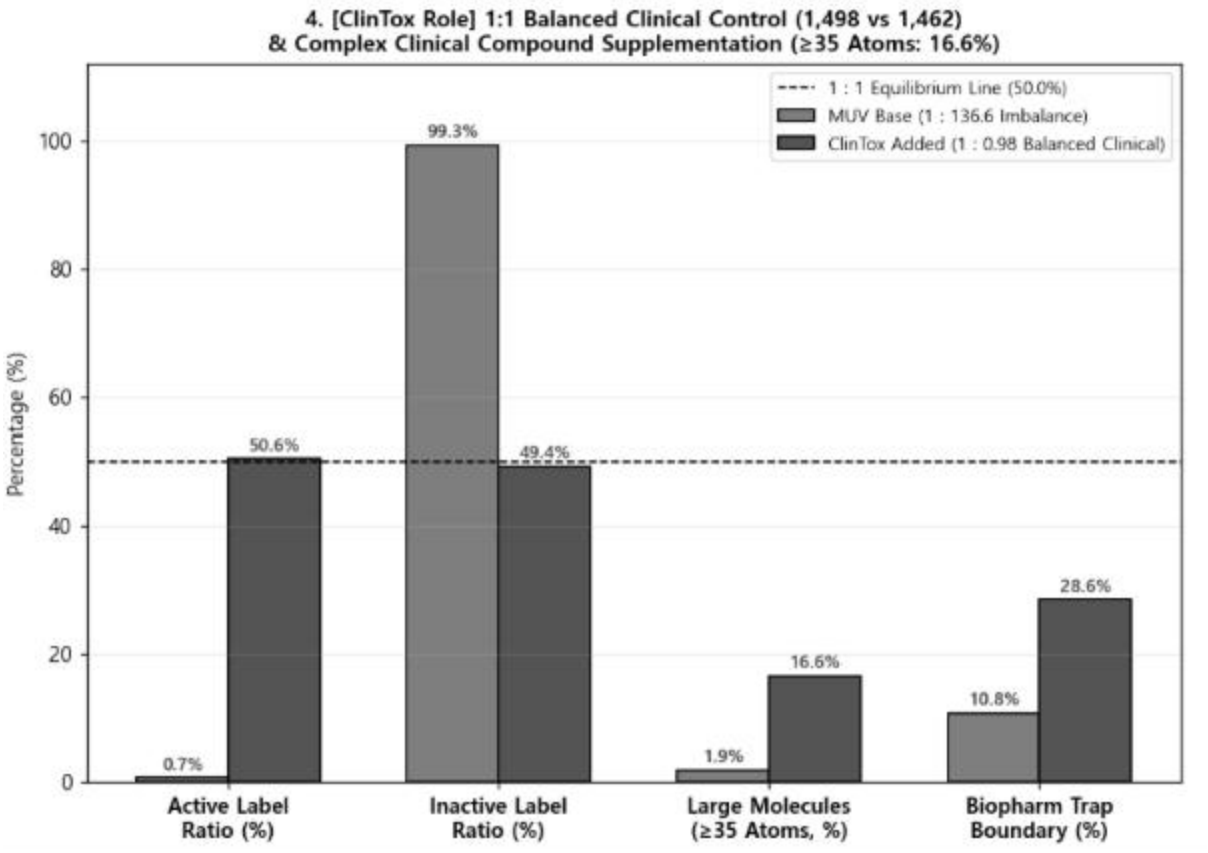
완전히 새로운 화학 공간의 분자를 만들어도 ood로 인한 무작위 찍기로 이어지지 않고, 순서대로 활성 물질을 나열할 수 있습니다.



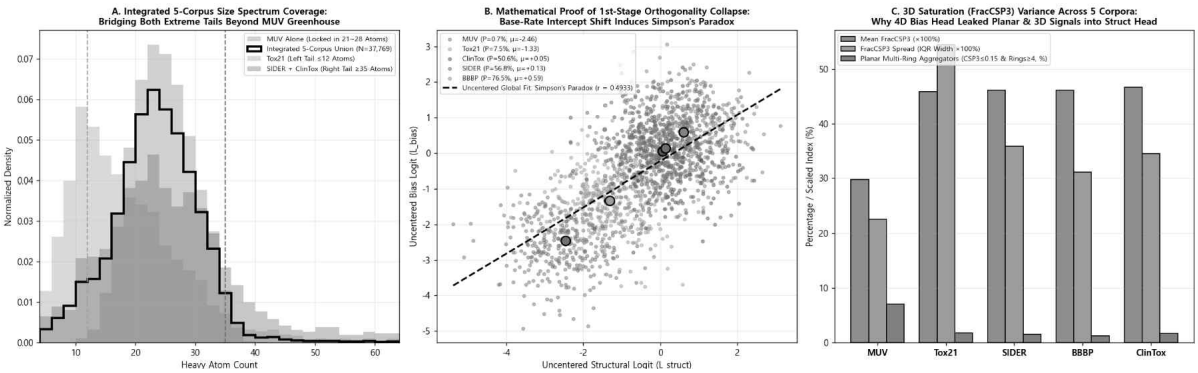
화합물은 세포막을 통과할 수 있는지 여부도 실제 활성 여부를 따질 때 중요한 기준이 됩니다. 위상 극성 표면적 TPSA 120 암스트롱 제곱은 일반적인 약물이 생체막을 자가 투고할 수 있는 물리적인 한계 경계선입니다. 이를 넘어가면 우측 음영 구역은 극성 면적이 너무 넓어 막을 뚫지 못합니다. 기름에 녹는 정도가 너무 높으면 비특이적 응집 즉, 기름이 뭉친 구역은 타깃이 아닌데 타깃이 아닌 곳에 결합하여 활성을 감지할 수 없는 위험 경계선이 (LogP= 5.0)이 됩니다. BBBP는 Blood-Brain Barrier Penetration 데이터셋으로 뇌혈관 장벽의 투과도를 다룹니다. 녹색의 원은 뇌 장벽을 뚫고 통과하는 활성 분자 n = 1,560,7651%이고 자주색의 x는 장벽을 통과하지 못하는 비활성 분자(n = 479, 23.49%)로 구성되어 있음을 보여줍니다.

해당 데이터셋은 극성 표면적 디스크립터의 경계선을 학습할 수 있게 합니다. 생약학적 함정 조건 중 하나가 TPSA > 120으로 이보다 작거나 같은 분자는 녹색 활성 분자들이 집중되며, 우측 120보다 큰 분자들은 대부분 비활성 분자들이 지배적입니다. 이를 통해 모델은 극성 표면적이 120Å² 을 넘어가면 약물이 막을 투과하지 못하여 비활성이 된다는 약동학적 생체 이용률(ADME)의 물리화학적 경계선을 알려 보정해줍니다.

해당 데이터셋은 기저 활성 비율이 76.51%로 활성 대 비활성 1: 0.31에 달합니다. 따라서 비활성이 주를 이루는 데이터셋 MUV로 인한 음수 로짓을 가장 강하게 양수로 올려주는 역할을 합니다. 이를 통해 압도적인 양성 비율을 확보하고 위음성을 극복할 수 있도록 임곗값을 정상 궤도로 복원합니다.



해당 데이터셋은 함정 비율이 높습니다. 임상 시험에 들어간 약물들은 분자 구조가 복잡하고 덩치가 커서 물리화학적 위험의 경계선을 넘나드는 물질이 있습니다. Shortcut이나 거나 룰 베이스드로 디스크립터 기준 일괄 배제를 해버리면 이 경계선의 물질이 실제 임상에 쓰이는정교한 대형 약물 후보군임에도 버리게 됩니다. 이는 데이터셋 차원으로 고차원 디컨파운딩 능력을 훈련시키는 역할을 합니다. Large Molecules이 >=35 Atoms: 16.6%로 대형 복합 임상 약물을 공급하여 화학 공간의 다양성을 넓혀줍니다. 또한 이 데이터셋은 전반적으로 좌측 active와 inactive 분자가 각각 50.6%, 49.4%의 거의 1:1 균형을 이루는 정확한 임상 대조군으로 구성이 됩니다. 전반적인 라벨 균형을 잡아주며 함정 경계선의 임상 분자들의 특징을 학습하도록 하여 정밀도를 끌어올리는 역할을 합니다.



5대 통합 코퍼스 분석입니다. 해당 코퍼스를 만듦으로 인해 화학 공간 크기 스펙트럼을 확장하고, 양 극단의 꼬리를 상호 보완하였습니다.

이 코퍼스들은 채널별 기저율이 극단적으로 격차가 있어 집단 교란이 발생할 수 있음을 산점도를 통해 사전 확인할 수 있습니다.(심슨의 역설은 코퍼스의 채널별 기저율 극단적 격차가 원인은 맞지만 부호의 변동을 설명하기 어려운 용어로 배제합니다.) 각 코퍼스 내부 순수 상관계수는 직교합니다. 그러나 채널별 평균 중심점의 차이로 우상향 양의 상관관계가 강하게 발생하는 것으로 보이는 착시가 발생하였으며 상관계수도 구조적 상관을 의미하는 것이 아니라 기저율 절편 차이로 인해 부풀려진 결과입니다.

입체성의 학습 측면에서 MUV는 평균적으로 FracCSP3기준으로 나열한 분자가 좌측에 분포하여(22%대) 입체성 학습에 제한적이였으나 추가한 코퍼스는 입체성이 높은 분자가 포함되어 우측까지 확장합니다.(46~50% 선) 이를 통해 화학적 3차원 다양성이 대폭 확보되었습니다. MUV는 FracCSP3 =<0.15 및 고리 수 4개 이상의 평면 응집 위험 분자가 7.1%를 차지했으나 다른 코퍼스에서는 안정화되었습니다. 기존 구조 헤드는 편향을 감지하는 축이 4개, 4D편향 헤드였으나 이때 3차원 포화도 축을 고려하지 못하였고 평면 응집으로 인한 탁해진 수용액이 신호가 되어 구조 임베딩에 입력이 되었고, V2아키텍쳐에선 5번째 편향 축을 추가하는 당위성을 보여주는 자료로 추가합니다.

이로써 준비 데이터셋에 대한 정리를 마칩니다.