제약·바이오 R&D의 AI 전환(AX) 역설 극복을 위한 자기 진단형 데이터 거버넌스 방법론: 비순환 직교 그래프 신경망 (NonCircularBenchScopeGNN)을 통한 표현 붕괴 및 집단 교란 통제 개념 증명

Overcoming the AI Transformation (AX) Paradox in Biopharmaceutical R&D: A Self-Auditing Data Governance Methodology for Controlling Representation Collapse and Group Confounding via Non-Circular Orthogonal Graph Neural Networks

김혜원 (Hye-Won Kim)[1,*]

[1] 모두의연구소 아이펠(AIFFEL) AI 리서처 과정 (AI Researcher Program, Modulabs)

[*] 교신저자 (Corresponding Author)

2026년 11월 6일

Abstract

배경. 분자 그래프 신경망(GNN)은 가상 스크리닝 벤치마크에서 높은 예측 성능을 보이나 습식 실험(Wet-lab) 검증에서 재현되지 않는 'AI 전환(AX)의 역설'이 반복되고 있다. 본 연구는 그 원인을 신경망 용량의 부족이 아니라 다음 두 가지에서 찾는다. 첫째, 학습 데이터셋의 물리화학적 지름길(Shortcut)과 시험관 아티팩트(Assay Trap)로 인해 구조 인코더 출력의 표본 간 분산이 소멸하는 구조 표현 붕괴(Representation Collapse), 둘째, 이종 코퍼스를 병합할 때 양성 기저율 격차가 유발하는 집단 교란(Group Confounding)이다.

방법. 특정 학습 가중치의 배포가 아니라, 기관이 자체 R&D 데이터와 사내 모델에 이식할 수 있는 4단계 자기 진단형(Self-Auditing) 데이터 거버넌스 방법론을 제안한다. 방법론은 (1) 샘플을 삭제하지 않는 무손실(Zero-Deletion) 5축 생물약제학 편향 정량화, (2) 채널 중심화와 직교 정규화를 통한 기저율 절편 교란 소거, (3) 절편 보존 탈편향 추론, (4) 이론적 상한선(Ceiling) 검증을 포함한 조기 인식 평가로 구성되며 `NonCircularBenchScopeGNN`으로 구현하였다.

결과. 방법론의 효과를 모델 용량과 분리하기 위해 4계층 GINEConv 백본의 구조를 201,733개 파라미터(44개 학습 텐서, BatchNorm 상태 버퍼 포함 68개 텐서)로 고정한 통제 실험(대조군 V1, 실험군 V2)을 수행하였다. 활성:디코이 = 1 : 510.01(양성 기저율 0.20%)의 단일 MUV 코퍼스(17채널)로 학습한 V1은 `ogbg-molhiv`($N = 4,113$)에서 구조 로짓 표준편차가 0.311로 수축하고 고신뢰 후보($p \geq 0.70$)를 0건(0.00%) 배출하였으며, 순수 구조 ROC-AUC가 0.4934($p = 7.99 \times 10^{-1}$, EF@1% 0.00×), `ogbg-molpcba`($N = 43,793,126$개 타깃)에서 평균 0.4607(무작위 기준 0.50 미만 역전)이었다. Tox21, SIDER, BBBP, ClinTox를 결합한 5대 통합 코퍼스(37,769건, 59채널, 유효 라벨 188,666개, 활성:비활성 = 1 : 5.03)에서는 코퍼스 간 기저율 격차(최대 105.26배, $\Delta\mu = 6.0976$)로 인해 채널 간 절편 공분산이 1.1423(전체 공분산 절대량의 98.5%)인 반면 채널 내부 순수 공분산은 -0.0177($r_{\text{within}} = -0.0120$, 사잇각 89.3° 직교)이었다. 채널 중심화 직교 거버넌스를 적용한 V2는 구조 로짓 표준편차를 2.115(6.8배)로 확장하고 정규화 어텐션 엔트로피를 0.9628에서 0.7056으로 샤프닝하였으며, 고신뢰 후보군 867건(21.08%)을 복원하였다. 그 결과 `ogbg-molhiv`에서 V2 순수 구조(결합채널) 모드는 물성 개입(V2 Bias EF@1% 0.00×)을 차단하고 ROC-AUC 0.6566($p = 1.15 \times 10^{-9}$), BEDROC(80.5) 0.2801(V1 0.0190 대비 14.7배), BEDROC(20.0) 0.3275(7.1배), EF@1% 8.29×(11/42 적중), EF@5% 6.45×(42/206 적중, V1 0.92× 대비

7.00배)로 도약하며 편향 포함(Total) 모드(AUC 0.6467, EF@1% 3.01×)까지 상회하였다. `ogbg-molpcba` 126개 타깃에서는 평균 순수 구조 ROC-AUC를 0.5073(59ch 통합)으로 복원하고 Mean BEDROC(80.5) 0.0518, Mean EF@1% 2.31×를 기록하였으며, 126개 타깃은 지름길 오염(Red, 80개, V1 0.4419 → V2 0.5193), 분포 불일치(Amber, 6개, 0.3856 → 0.5003), 모델 정합 양호(Green, 40개, 0.5097 → 0.4845)의 3등급으로 분류되어 전체 평균과 수학적으로 완벽히 일치하였다.
결론. 모델 대형화 없이 데이터-모델 정렬과 직교 거버넌스만으로 구조 표현 붕괴와 집단 교란을 진단·완화할 수 있음을 통제된 개념 증명(PoC)으로 확인하였으며, 3등급(Signal-Light) 타깃 감사 체계를 R&D 의사결정 지원을 위한 데이터 품질 감사 표준으로 제안한다.

키워드: 가상 스크리닝, 그래프 신경망, 지름길 학습, 표현 붕괴, 집단 교란, 직교 정규화, 데이터 거버넌스, BEDROC

Abstract

Background. Graph neural networks (GNNs) for virtual screening report high benchmark performance that is often not reproduced in wet-lab validation, a phenomenon we term the AI transformation (AX) paradox. We attribute it not to insufficient model capacity but to (i) representation collapse, in which physicochemical shortcuts and assay traps in the training data eliminate the between-sample variance of the structural encoder output, and (ii) group confounding induced by base-rate gaps when heterogeneous corpora are merged.
Methods. Rather than distributing trained weights, we propose a four-stage self-auditing data governance methodology that an organization can transplant onto its own R&D data and in-house models: (1) zero-deletion five-axis biopharmaceutical bias quantification, (2) channel centering with orthogonal regularization to remove base-rate intercept confounding, (3) intercept-preserved deconfounded inference, and (4) early-recognition evaluation with theoretical ceiling verification. The methodology is implemented as `NonCircularBenchScopeGNN`.
Results. In a controlled experiment fixing the 4-layer GINEConv backbone at 201,733 parameters, the control model V1, trained on a single MUV corpus (active:decoy = 1 : 510.01, base rate 0.20%, 17 channels), exhibited a contracted structural-logit standard deviation of 0.311 (0 high-confidence hits at $p \geq 0.70$), a pure-structure ROC-AUC of 0.4934 ($p = 7.99 \times 10^{-1}$, EF@1% = 0.00×) on `ogbg-molhiv` ($N = 4,113$), and a mean ROC-AUC of 0.4607 on `ogbg-molpcba` ($N = 43,793$; 126 targets). In the five-corpus union (37,769 molecules, 59 channels, 188,666 valid labels, active:inactive = 1 : 5.03), base-rate gaps of up to 105.26-fold ($\Delta\mu = 6.0976$) induced a between-channel intercept covariance of 1.1423 (98.5% of covariance magnitude), whereas the within-channel covariance was −0.0177 ($r_{\text{within}} = -0.0120$). With channel-centered orthogonal governance, V2 expanded the structural-logit standard deviation to 2.115 (6.8-fold), sharpened normalized node attention entropy from 0.9628 to 0.7056, and restored 867 high-confidence candidates (21.08%). On `ogbg-molhiv`, V2 pure-structure mode achieved a ROC-AUC of 0.6566 ($p = 1.15 \times 10^{-9}$), BEDROC(80.5) of 0.2801 (14.7-fold over V1), BEDROC(20.0) of 0.3275 (7.1-fold), EF@1% of 8.29× (11/42 hits), and EF@5% of 6.45× (42/206 hits, 7.00-fold over V1), outperforming even the bias-included Total mode (AUC 0.6467, EF@1% 3.01×). On `ogbg-molpcba`, V2 restored mean pure-structure ROC-AUC from 0.4607 to 0.5073 (59ch) with Mean BEDROC(80.5) of 0.0518 and Mean EF@1% of 2.31×, while classifying the 126 targets into shortcut-contaminated (Red, 80 targets: 0.4419 → 0.5193), distribution-mismatched (Amber, 6 targets: 0.3856 → 0.5003), and model-aligned (Green, 40 targets: 0.5097 → 0.4845) tiers with exact mathematical consistency.
Conclusion. Without enlarging the model, data-model alignment and orthogonal governance alone can diagnose and mitigate structural-representation collapse and group confounding, as shown in a controlled proof of concept (PoC).

Keywords: virtual screening; graph neural network; shortcut learning; representation collapse; group confounding; orthogonal regularization; data governance; BEDROC

1 서론 (Introduction)

1.1 제약·바이오 AX의 역설과 매몰 비용

신약 개발 초기 단계의 가상 스크리닝(Virtual Screening)에는 딥러닝, 특히 분자 그래프 신경망(Graph Neural Network, GNN)이 광범위하게 도입되고 있다. 그러나 벤치마크에서 높은 AUROC를 기록한 모델이 습식 실험(Wet-lab)에서는 진성 활성 물질을 선별하지 못하거나 위양성(False Positive) 후보를 상위에 배치하여 R&D 예산을 소모하는 사례가 반복된다. 본 연구는 벤치마크 성능과 실험적 검증 사이의 이러한 불일치를 'AI 전환(AX)의 역설'로 지칭한다.

이 불일치의 핵심 기전은 물리화학적 지름길(Shortcut)과 시험관 아티팩트(Assay Trap)이다. 과도한 지용성(LogP > 5.0)은 수용액에서 콜로이드성 응집을 일으켜 비특이적 활성 신호를 만들 수 있고 [7], 평면 다중고리 구조(FracCSP3 ≤ 0.15, 고리 수 ≥ 4)는 π-π 스태킹(Stacking)에 의한 응집과 광학 신호 간섭을 통해 가짜 활성을 유발할 수 있다 [6, 8]. 또한 위상 극성 표면적(TPSA)이 120 Å^2를 초과하는 분자는 생체막 투과의 경험적 한계를 벗어난다. 신경망이 표적 결합에 기여하는 약효 작용기(Pharmacophore) 대신 이러한 1차원 전역 물성을 활성과 상관된 신호로 학습하는 것은 지름길 학습(Shortcut Learning)의 전형적인 사례이며 [9], 이를 걸러내지 못하면 벤치마크 상위 후보에 대한 R&D 의사결정 오류와 매몰 비용으로 이어진다.

1.2 기존 접근법의 두 가지 맹점

맹점 1: 단일 정제 코퍼스의 구조 표현 붕괴. 활성 분자와 디코이 사이의 근접 이웃 거리 편향을 공간 통계로 억제한 MUV [1]는 단순 기술자나 골격 거리에 의한 분리를 차단한 데이터셋이다. 그러나 그 대가로 MUV 원본 전체(93,087건, 17채널)는 유효 라벨 249,886개 중 활성이 489개, 디코이가 249,397개로 활성:디코이 $= 1 : 510.01$(양성 기저율 0.1957%, 약 0.20%)의 극단적 희소성을 가지며, 중원자 수가 21–28개(IQR)에 집중된 좁은 크기 분포를 가진다. 이진 교차 엔트로피(BCE) 손실 하에서 양성 기저율 P_t가 0에 가까운 채널은 입력과 무관하게 사전 로그오즈 $\ln(P_t/(1-P_t))$를 출력하는 상수 예측기로도 낮은 손실을 달성할 수 있다. 이때 저차원 연속 변수인 물성 편향 벡터가 절편과 물성 경계를 먼저 흡수하면 고차원 그래프 표현을 통한 구조 헤드의 학습 신호가 약화된다. 본 연구는 그 결과로 구조 헤드 로짓의 표본 간 표준편차가 0 근처로 수축하는 현상을 구조 표현 붕괴(Representation Collapse)로 정의하고, 이것이 단일 MUV 코퍼스로 학습한 모델에서 관찰되는지를 검증한다(가설 H1).

맹점 2: 다중 코퍼스 병합 시의 집단 교란. 표현 붕괴를 완화하기 위해 이종 R&D 코퍼스를 병합하면 새로운 문제가 발생한다. 양성 기저율이 극히 낮은 탐색 스크리닝 데이터(MUV 서브셋, 0.73%)와 기저율이 높은 임상·부작용 데이터(SIDER 56.76%, BBBP 76.51%)를 결합하면 기저율 격차(최대 105.26배)가 채널 간 절편 차이를 만든다. 각 채널 내부에서는 구조 점수와 편향 점수가 사실상 완전 직교($r_{\text{within}} = -0.0120$, 사잇각 89.3°) 임에도 미보정 합산 상관계수는 0.3574(초기 학습 6 에폭 시점 최대 0.4933)까지 부풀려진다. 이는 구조적 상관이 아니라 기저율 절편 차이에 의한 집단 교란이다. 합산 상관이 양(+)으로 유도되고 부호 역전이 주된 현상이 아니므로, 본 연구는 이를 고전적 심슨의 역설과 구별하여 '집단 교란(심슨 유형 병합 착시)'으로 지칭한다.

1.3 연구 질문과 연구 방법

본 연구의 핵심 질문은 다음과 같다. "모델 용량을 고정한 조건에서, 데이터셋 정렬과 직교 거버넌스만으로 구조 표현 붕괴와 집단 교란을 진단·완화하여 외부 스크리닝 분포에서의 조기 인식 성능을 복원할 수 있는가?" 이를 디자인 과학 연구 방법론 [12]에 따라, 모델을 단순 예측기가 아니라 데이터셋 무결성을 감사하는 아티팩트(자기 진단 도구)로 설계하고 통제 실험으로 평가한다. 방법론의 순수 효과를 분리하기 위해 대조군(V1)과 실험군(V2)의 4계층 GINEConv 백본 아키텍처를 201,733개 파라미터로 동일하게 고정하며, V2에서 증가한 파라미터는 다중 채널 출력 분류 헤드와 5차원 편향 헤드의 3,980개(+1.88%)에 한정한다.

1.4 연구의 위치: 방법론 제안과 통제된 개념 증명

본 연구의 산출물은 특정 표적에 특화된 예측 모델이나 완성형 가중치가 아니다. 제안하는 것은 (i) 데이터셋과 모델 사이의 정합성을 진단하고 (ii) 이종 데이터 병합 시 기저율 교란을 직교 분리하는 4단계 데이터 거버넌스 방법론이다. 본 연구에서 사용한 동결 가중치(V1 859.6 KB, V2 875.0 KB)는 이 방법론이 통제 조건에서 작동함을 확인하기 위한 계측 도구이며, 보고되는 성능 수치는 방법론의 효과를 모델 용량과 분리하여 측정하기 위한 것이지 특정 가중치의 절대 성능을 주장하기 위한 것이 아니다. 따라서 현업 적용은 가중치의 재사용이 아니라 기관 자체의 R&D 데이터와 사내 모델에 본 방법론의 절차를 이식하는 방식이어야 한다.

1.5 연구의 기여

1. **구조 표현 붕괴의 정량적 규명:** 99.80%가 비활성 디코이인 환경에서 구조 로짓 표준편차가 0.311로 수축하고 고신뢰 후보($p \geq 0.70$)가 0건(0.00%)으로 마비되며 정규화 어텐션 엔트로피가 0.9628(균등 분산)에 머무는 내부 붕괴 메커니즘을 정량화하였다.

2. **3층위 채널 중심화 및 비순환 직교 거버넌스 방법론의 정립:** 아키텍처 수준 중심화(층위 ①), 기저율 로그오즈 절편 분리(층위 ②), 채널 내부 직교 정규화(층위 ③)를 결합하여 채널 간 절편 공분산($\mathrm{Cov}_{\mathrm{between}} = 1.1423$, 전체 공분산 절대량의 98.5%)을 0.0000으로 소거하고 순수 내부 공분산($\mathrm{Cov}_{\mathrm{within}} = -0.0177$)만을 통제한다.

3. **백본 용량 통제(201,733개 고정)를 통한 개념 증명:** 외부 벤치마크 `ogbg-molhiv`와 `ogbg-molpcba`(126개 타깃)에서 순수 구조 모드의 조기 인식 지표가 V1 대비 대폭 향상됨을 보였다(`molhiv` ROC-AUC 0.4934 → 0.6566, BEDROC(80.5) 0.0190 → 0.2801 [14.7배], EF@1% 0.00× → 8.29×, EF@5% 0.92× → 6.45× [7.00배]; `molpcba` 평균 구조 ROC-AUC 0.4607 → 0.5073).

4. **3등급(Signal-Light) 의사결정 프레임워크:** 126개 타깃을 지름길 오염(Red, 80개), 분포 불일치(Amber, 6개), 모델 정합 양호(Green, 40개)로 분류하여 건식(Dry-lab) AI와 습식(Wet-lab) 실험 사이의 R&D 리스크 관리 프로토콜을 제시한다.

2 배경 및 선행연구 (Background and Related Works)

2.1 분자 그래프 신경망과 지름길 학습

GIN은 이웃 집계의 단사성(Injectivity)을 통해 메시지 패싱 신경망의 판별력을 Weisfeiler-Lehman(WL) 검정 수준으로 끌어올린 모델이며 [13], GINEConv는 이를 결합(Edge) 특징으로 확장한 변형으로 분자 그래프 사전학습 연구에서 제안되었다 [14]. Jumping Knowledge Networks는 각 층의 표현을 결합하여 노드별로 적응적인 수용 영역을 제공한다 [10]. 이러한 구조적 발전에도 불구하고 심층 신경망은 의도한 해 대신 데이터셋에 내재한 우연한 상관을 활용하는 지름길 학습을 수행할 수 있다 [9]. 분자 영역에서는 분자량(MW), 지용성(LogP)과 같은 1차원 전역 물성이 활성 라벨과 상관될 때 모델이 2D·3D 결합 위상 대신 이를 학습할 수 있다는 점이 핵심 병목이 된다.

2.2 가상 스크리닝 벤치마크의 진화와 내재한 딜레마

초기 합성 디코이 기반 벤치마크인 DUD-E [5]는 활성 분자와 물성이 유사한 디코이를 알고리즘적으로 구성하였으나, 이후 후속 연구에서 단순 기술자나 골격 간 거리만으로 활성과 디코이가 쉽게 분리되는 구조적 편향이 지적되었다 [18, 19]. 공간 통계학(근접 이웃 함수)으로 이 편향을 엄격히 억제한 MUV [1]는 거리 편향 통제라는 목적을 달성하지만, 본 연구의 전수 검증에서 확인되듯 활성:디코이 = 1 : 510.01(0.20%)의 극단적 불균형과 중원자 수 21 28개(중앙값 24개)의 좁은 온실 분포를 수반한다. 한편 골격 분할(Scaffold

Split)을 채택한 OGB의 `ogbg-molhiv`와 `ogbg-molpcba` [3]는 MoleculeNet [4]에서 유래한 대규모 벤치마크로, 학습 분포 밖(Out-of-Distribution, OOD) 일반화를 평가하는 데 널리 사용된다.

2.3 이종 코퍼스 병합과 집단 교란

집단 수준에서 계산한 상관이 개체 수준의 상관과 달라지는 현상은 생태학적 상관 [15]으로 알려져 있으며, 집단을 합쳤을 때 상관의 부호가 역전되는 극단적 경우가 심슨의 역설 [16]이다. 본 연구의 병합 코퍼스에서는 미보정 합산 상관이 채널 내부 상관보다 크게 부풀려지므로 '집단 교란(심슨 유형 병합 착시)'으로 정의한다. 전공분산 법칙(Law of Total Covariance)에 따르면 전체 합산 공분산은 그룹 내 공분산의 기댓값과 그룹 평균 간 공분산의 합으로 분해되며, 각 그룹 평균을 제거(채널 중심화)하면 후자가 항등적으로 0이 된다. 이는 마할라노비스 거리 [17]가 요구하는 공분산 구조 중 그룹 내 공분산($\mathbf{\Sigma}_W$)만을 남기는 연산에 해당한다.

2.4 제약 R&D 의사결정 지원과 데이터 중심 AI 거버넌스

디자인 과학 연구는 정보시스템 분야에서 문제 해결을 위한 아티팩트를 설계하고 그 유용성을 평가하는 방법론이다 [12]. 본 연구는 이 관점에서 GNN을 단순 예측기가 아니라 학습 데이터셋의 지름길과 기저율 교란을 드러내는 자기 진단(Self-Auditing) 아티팩트로 정의하고, 모델 대형화 경쟁 대신 데이터 무결성 및 직교 정렬 우선 접근이 R&D 의사결정의 품질을 복원할 수 있는지를 평가한다.

3 수리적 문제 정의 (Problem Formulation)

3.1 다중 코퍼스 블록 대각 구조와 가산형 양갈래 로짓 분해

K개의 이종 코퍼스(본 연구에서 $K = 5$)가 결합된 분자 집합을 $\mathcal{G} = \{G_1, \ldots, G_N\}$ ($N = 37,769$), 전체 태스크 채널 수를 $T = 59$로 둔다. 라벨 행렬 $\mathbf{Y} \in \{0, 1, \mathrm{NaN}\}^{N \times T}$는 관측된 유효 라벨 집합 $\Omega = \{(i, t) \mid Y_{i,t} \neq \mathrm{NaN}\}$ ($|\Omega| = 188,666$)에서만 정의되며, 각 코퍼스는 자신에게 속한 채널에 대해서만 라벨을 가지는 블록 대각(Block-Diagonal) 구조를 이룬다. 분자 i의 채널 t에 대한 전체 예측 로짓 $L_{\mathrm{total},i,t}$는 순수 구조 헤드 출력 $L_{\mathrm{struct},i,t}$와 물성 편향 헤드 출력 $L_{\mathrm{bias},i,t}$의 합으로 정의한다:

$$L_{\mathrm{total},i,t} = L_{\mathrm{struct},i,t} + L_{\mathrm{bias},i,t} \tag{1}$$

채널 t의 양성 기저율을 $P_t = P(Y_t = 1)$로 두면, 이에 대응하는 목표 로그오즈 절편 μ_t는 다음과 같다:

$$\mu_t = \ln\left(\frac{P_t}{1 - P_t}\right) \tag{2}$$

3.2 극단적 불균형 하에서의 구조 표현 붕괴

양성 기저율 P_t가 0에 근접하는 극단적 희소 환경(MUV 원본 $P_t \approx 0.0020$, $1 : 510.01$)에서 표준 BCE 손실을 최소화하면 비활성 샘플(99.80%)이 유발하는 위양성 페널티가 기울기를 지배한다. 저차원 연속 변수인 L_{bias}가 기저율 절편과 물성 경계를 빠르게 흡수하면, 고차원 그래프 위상을 학습해야 할 구조 헤드 L_{struct}의 표본 간 표준편차가 수축한다. 본 연구는 다음 두 조건이 함께 관찰되는 상태를 구조 표현 붕괴(Representation Collapse)로 정의한다:

$$\mathrm{Std}_i(L_{\mathrm{struct},i,t}) \to \epsilon \tag{3}$$

$$H_{\mathrm{norm},i} = \frac{H_i}{\ln N_i} \to 1.0 \tag{4}$$

여기서 $H_i = -\sum_{v \in G_i} \alpha_v \ln \alpha_v$는 분자 i의 노드 어텐션 분포 $\{\alpha_v\}$의 엔트로피이고, N_i는 중원자 수이다. $H_{\text{norm},i}$가 1에 가까우면 어텐션이 노드 전체에 균등하게 분산되어 특정 약효 작용기에 대한 선택성이 상실되었음을 뜻한다(본 연구의 V1 실측값은 $\epsilon = 0.311$, $H_{\text{norm}} = 0.9628$).

3.3 전공분산 법칙에 의한 집단 교란의 정의

서로 다른 기저율을 가진 채널을 병합하면(예: MUV $P_t = 0.73\%$, BBBP $P_t = 76.51\%$) 각 채널이 수렴해야 할 목표 절편 μ_t가 채널마다 크게 달라진다. 가산형 모델에서 μ_t가 두 헤드의 채널 평균 $\mu_{S,t} = \mathbb{E}_i[L_{\text{struct},i,t}]$와 $\mu_{B,t} = \mathbb{E}_i[L_{\text{bias},i,t}]$로 분담($\mu_{S,t} + \mu_{B,t} \approx \mu_t$)될 때, 중심화 없이 59개 채널 전체의 유효 라벨에서 측정한 전체 공분산은 전공분산 법칙(Law of Total Covariance)에 의해 다음과 같이 분해된다:

$$\text{Cov}_{\text{total}}(L_{\text{struct}}, L_{\text{bias}}) = \mathbb{E}_t\left[\text{Cov}_{\text{within}}(L_{\text{struct},t}, L_{\text{bias},t})\right] + \text{Cov}_{\text{between}}(\mu_{S,t}, \mu_{B,t}) \tag{5}$$

첫째 항 $\text{Cov}_{\text{within}}$은 각 채널 내부에서 구조 점수와 편향 점수가 실제로 함께 변하는 정도(그룹 내 공분산 $\mathbf{\Sigma}_W$의 비대각 원소)이고, 둘째 항 $\text{Cov}_{\text{between}}$은 단지 채널마다 기저율 절편이 다르다는 사실만으로 발생하는 그룹 간 절편 공분산(그룹 간 공분산 $\mathbf{\Sigma}_B$의 비대각 원소)이다. 채널 간 기저율 격차가 크면(본 연구 $\Delta\mu = 6.0976$), 각 채널 내부에서 두 헤드가 직교($\text{Cov}_{\text{within}} \approx 0$)하더라도 $|\text{Cov}_{\text{between}}| \gg |\text{Cov}_{\text{within}}|$이 되어 미보정 합산 상관계수가 크게 왜곡된다:

$$r_{\text{uncentered}} = \frac{\text{Cov}_{\text{total}}}{\text{Std}_{\text{total}}(L_{\text{struct}}) \cdot \text{Std}_{\text{total}}(L_{\text{bias}})} \tag{6}$$

3.4 추론 시 절편 소실에 의한 확률 역전

불균형 코퍼스로 학습한 뒤 편향 헤드가 음수 절편($\mu_{B,t} < 0$)을 분담한 상태에서 추론 시 단순히 $L_{\text{bias},i,t} = 0$으로 마스킹하면 음수 절편이 소실된다. 그 결과 $L_{\text{bias},i,t} < 0$인 분자에 대해 구조 단독 시그모이드 확률 $\sigma(L_{\text{struct},i,t})$가 전체 확률보다 일괄적으로 높아지는 확률 역전 왜곡이 발생한다:

$$\sigma(L_{\text{struct},i,t}) > \sigma(L_{\text{struct},i,t} + L_{\text{bias},i,t}) \quad (\text{when } L_{\text{bias},i,t} < 0) \tag{7}$$

4 제안 방법론: NonCircularBenchScopeGNN과 4단계 거버넌스

4.1 고정 백본 아키텍처 명세 (201,733개 파라미터 통제 설계)

`NonCircularBenchScopeGNN`은 공유 백본 인코더 뒤에 두 헤드를 병렬로 부착한 구조이다. 순수 구조 헤드(`structural_head`)는 그래프 임베딩 $\mathbf{z}_i$만을, 물성 편향 흡수 헤드(`bias_only_head`)는 사전 계산된 편향 텐서 $\mathbf{B}_{\text{bias},i}$만을 입력으로 받으며, 한 헤드의 출력이 다른 헤드의 입력이 되지 않는 비순환(Non-Circular) 구조이다.

원자 특징(9차원)과 결합 특징(3차원)은 각각 128차원으로 투영된다(`Linear` $9 \to 128$, 1,280개; `Linear` $3 \to 128$, 512개). 4계층 GINEConv(각 계층: 2층 MLP $128 \to 128 \to 128$, `BatchNorm1d`, `ReLU`, `train_eps=True`)와 외부 `BatchNorm1d`가 메시지 패싱을 수행하며(계층당 33,537개, 4계층 합계 134,148개), 네 계층의 노드 표현을 연결(Jumping Knowledge, 512차원)하여 128차원으로 투영한 뒤(`Linear` $512 \to 128$, 65,664개) 크기 보정 어텐션 게이트(`Linear` $128 \to 1$, 129개)가 산출한 노드 가중치로 그래프 표현 $\mathbf{z}_i \in \mathbb{R}^{128}$을 구성한다:

$$a_v = \frac{\text{raw_att}_v}{\tau_i}, \quad \alpha_v = \text{softmax}_{v \in G_i}(a_v), \quad \mathbf{z}_i = \sum_{v \in G_i} \alpha_v \mathbf{h}_v \tag{8}$$

백본 파라미터의 합은 $1,792 + 134,148 + 65,793 = 201,733$개(학습 파라미터 텐서 44개, BatchNorm의 `running_mean`/`var` 및 `num_batches_tracked` 상태 버퍼 24개를 포함한 `state_dict` 기준 68개 텐서)이다.

두 헤드는 `structural_head`($128 \to 64 \to T$; `ReLU`, `Dropout` 0.2)와 `bias_only_head`($D_{\text{bias}} \to H_{\text{bias}} \to T$; `ReLU`)이다. V1($T = 17$)의 `structural_head`는 9,361개, `bias_only_head`($4 \to 16 \to 17$)는 369개이고, V2($T = 59$)의 `structural_head`는 12,091개(+2,730개), `bias_only_head`($5 \to 24 \to 59$)는 1,619개(+1,250개)이다(표 1).

Table 1: V1 대 V2 아키텍처 및 가중치 텐서 감사 (백본 구조 100% 동일, 출력 헤드만 확장)

모듈 계층명	구분	텐서 수†	가중치 형상 (V1 → V2)	V1 파라미터	V2 파라미터	증감(Δ)	L2 노름
1. `node_emb`	백본(고정)	2 (2)	(128, 9) 동일	1,280	1,280	+0	6.65 → 7.17
2. `edge_emb`	백본(고정)	2 (2)	(128, 3) 동일	512	512	+0	8.03 → 7.57
3. `convs.0+bns.0`	백본(고정)	9 (15)	(1,), (128, 128) 동일	33,537	33,537	+0	72.34 → 53.24
4. `convs.1+bns.1`	백본(고정)	9 (15)	(1,), (128, 128) 동일	33,537	33,537	+0	97.34 → 53.58
5. `convs.2+bns.2`	백본(고정)	9 (15)	(1,), (128, 128) 동일	33,537	33,537	+0	184.30 → 86.52
6. `convs.3+bns.3`	백본(고정)	9 (15)	(1,), (128, 128) 동일	33,537	33,537	+0	341.96 → 166.15
7. `jk_linear`	백본(고정)	2 (2)	(128, 512) 동일	65,664	65,664	+0	8.39 → 8.76
8. `att_gate`	백본(고정)	2 (2)	(1, 128) 동일	129	129	+0	0.51 → 0.58
[소계] 백본 인코더	**통제 변인**	**44 (68)**	**9→128→512→128→1**	**201,733**	**201,733**	**+0 (0.00%)**	-
9. `structural_head`	구조 헤드	4 (4)	(17, 64) → (59, 64)	9,361	12,091	+2,730	6.16 → 7.69
10. `bias_only_head`	편향 헤드	4 (4)	(16, 4) → (24, 5), (59, 24)	369	1,619	+1,250	5.93 → 7.42
[총계] 전체 모델	**전체 합계**	**52 (76)**	**859.6 KB → 875.0 KB**	**211,463**	**215,443**	**+3,980 (+1.88%)**	-

† 학습 가능한 파라미터 텐서 수(`named_parameters()` 기준 52개) 및 괄호 안은 BatchNorm 상태 버퍼를 포함한 `state_dict` 총 텐서 수(76개).

4.2 1단계: 무손실(Zero-Deletion) 5축 생물약제학 편향 정량화

어떠한 분자도 인위적으로 삭제하지 않고 모든 화학 자산을 보존하면서 다음 세 가지 보정 인자를 산출한다:

1. **골격 독점 억제 역가중치:** Bemis-Murcko 골격 [11] 군집 $s(i)$의 크기 $|C_{s(i)}|$에 대해 다음 역가중치를 부여하여 특정 골격의 기울기 독점을 방지한다:

$$w_{\text{red},i} = \frac{1.0}{\sqrt{|C_{s(i)}|}} \tag{9}$$

2. **크기 적응형 어텐션 온도:** MUV 중원자 수 중앙값(24개)을 기준점으로 삼아 노드 어텐션 로짓을 스케일링한다:

$$\tau_i = \text{clip}\left(\sqrt{\frac{24.0}{\max(N_i, 6.0)}},\ 0.45,\ 1.35\right) \tag{10}$$

3. **5차원 생물약제학 편향 텐서:** V1의 4차원 편향 벡터에 3차원 탄소 포화도(FracCSP3) 연속 축을 추가하여 $\mathbf{B}_{\text{bias},i} = [z_{\text{MW}}, z_{\text{LogP}}, z_{\text{TPSA}}, z_{\text{CSP3}}, I_{\text{trap}}] \in \mathbb{R}^5$를 구성한다:

$$z_{\text{MW}} = \frac{\text{MW} - 350.0}{80.0}, \quad z_{\text{LogP}} = \frac{\text{LogP} - 3.0}{1.5}, \quad z_{\text{TPSA}} = \frac{\text{TPSA} - 75.0}{35.0}, \quad z_{\text{CSP3}} = \frac{\text{FracCSP3} - 0.27}{0.15} \tag{11}$$

$$I_{\text{trap}} = \mathbb{I}\Big[(\text{LogP} > 5.0) \vee (\text{TPSA} > 120.0) \vee (\text{FracCSP3} \leq 0.15 \wedge \text{NumRings} \geq 4)\Big] \tag{12}$$

4.3 2단계: 3층위 채널 중심화와 직교 정규화

집단 교란($\text{Cov}_{\text{between}}$)을 제거하고 마할라노비스 공분산 구조 중 그룹 내 공분산($\mathbf{\Sigma}_W$)만을 통제하기 위해 세 층위를 결합한다.

층위① 아키텍처 수준 구조적 중심화. 각 헤드 출력 직후 채널별 평균을 차감하는 무파라미터(0-Param) 투영을 적용하여 $\mathbb{E}_i[\hat{z}_{\text{struct},i,t}] = 0$, $\mathbb{E}_i[\hat{z}_{\text{bias},i,t}] = 0$ 및 $\text{Cov}_{\text{between}} = 0.0000$을 구조적으로 보장한다:

$$\hat{z}_{\text{struct},i,t} = L_{\text{struct},i,t} - \mu_{S,t}, \quad \hat{z}_{\text{bias},i,t} = L_{\text{bias},i,t} - \mu_{B,t} \tag{13}$$

층위② 목표 기저율 절편의 명시적 분리. 채널별 사전확률 절편 상수 $b_t = \ln(P_t/(1-P_t)) \approx \mu_{S,t} + \mu_{B,t}$를 분리하여 최종 로짓을 구성한다:

$$L_{\text{total},i,t} = \hat{z}_{\text{struct},i,t} + \hat{z}_{\text{bias},i,t} + b_t \tag{14}$$

층위③ 채널 내부 직교 정규화와 엔트로피 샤프닝 손실. 채널별 동적 양성 가중치 $p_t = \text{clip}(N_{\text{neg},t}/N_{\text{pos},t}, 1.0, 50.0)$와 유효 라벨 밀도 가중치 $\beta_t = \text{clip}(\sqrt{\text{Avg_Valid}/\text{Valid}_t}, 0.5, 3.0)$를 적용한 가중 BCE에, 유효 마스크 Ω_t 내 표준화 잔차 간의 채널별 피어슨 상관계수 제곱 평균인 직교 페널티 $\mathcal{L}_{\text{ortho}} = \frac{1}{|T_{\text{valid}}|}\sum_t \text{Corr}_i(\hat{z}_{\text{struct},i,t}, \hat{z}_{\text{bias},i,t})^2$와 엔트로피 샤프닝 페널티를 결합한다($\lambda_{\text{ortho}} = 0.15, \lambda_{\text{ent}} = 0.005$):

$$\mathcal{L} = \mathcal{L}_{\text{BCE}}(w_{\text{red}}, p_t, \beta_t) + \lambda_{\text{ortho}}\mathcal{L}_{\text{ortho}}(\hat{z}_{\text{struct}}, \hat{z}_{\text{bias}}) + \lambda_{\text{ent}}\frac{1}{B}\sum_{i=1}^{B} H_i \tag{15}$$

4.4 3단계: 절편 보존 탈편향 추론

추론 시에는 분자별 물성 지름길 편차 $\hat{z}_{\text{bias},i,t} = L_{\text{bias},i,t} - \mathbb{E}[L_{\text{bias},t}]$만을 도려내고 기저 사전확률 절편은 보존하는 탈편향 구조 로짓을 산출한다:

$$L_{\text{carved},i,t} = L_{\text{struct},i,t} + \mathbb{E}[L_{\text{bias},t}] = \hat{z}_{\text{struct},i,t} + b_t \tag{16}$$

모델 간 확률 분포를 비교할 때에는 공통 기준 절편 $\mu_{\text{ref}} = -1.150$으로 영점 정렬한 확률 $p_{\text{aligned},i} = \sigma(L_{\text{carved},i} - \mathbb{E}[L_{\text{carved}}] + \mu_{\text{ref}})$를 사용하여 우측 고신뢰 활성 꼬리($p \geq 0.70$)의 복원율을 감사한다.

4.5 4단계: BEDROC 및 이론적 상한선(Ceiling) 검증

조기 인식 성능은 Truchon & Bayly [2]의 BEDROC($\alpha = 80.5, 20.0$)와 상위 1%·5% 농축 계수(EF@1%, EF@5%)로 평가한다. N개 분자 중 n개 활성의 내림차순 순위(1-기반)를 r_i, $R_a = n/N$이라 할 때 다음과 같다:

$$\text{RIE}_\alpha = \frac{\frac{1}{n}\sum_{i=1}^{n}\exp(-\alpha r_i/N)}{\frac{1}{N}\frac{1-\exp(-\alpha)}{\exp(\alpha/N)-1}} \tag{17}$$

$$\text{BEDROC}_\alpha = \text{RIE}_\alpha\frac{R_a\sinh(\alpha/2)}{\cosh(\alpha/2)-\cosh(\alpha/2-\alpha R_a)} + \frac{1}{1-\exp(\alpha(1-R_a))} \tag{18}$$

$$\text{EF@}x\% = \frac{h_x/k_x}{n/N}, \quad k_x = \lceil (x/100)\cdot N \rceil \tag{19}$$

산출된 BEDROC_α가 실제 적중 건수 h_1, h_5가 허용하는 수학적 최댓값 $\text{BEDROC_Ceil}(h_1, h_5; \alpha)$ 이하인지를 전수 검증(PASS/FAIL)하여 지표 산출의 수리적 무결성을 보증한다(부록 A.3).

5 벤치마크 요약 및 데이터셋 정렬 명세

5.1 학습 코퍼스 구성: 대조군 V1(단일 MUV) 대 실험군 V2(5대 통합 코퍼스)

대조군 V1은 MUV 원본 전체(93,087건, 17채널)로 학습한다. 실험군 V2는 MUV의 활성 라벨 489개를 100% 보존한 25,000건 서브셋을 기저로 독성·시판 약물·임상 코퍼스인 Tox21, SIDER, BBBP, ClinTox를 병합하여 총 37,769건, 59채널, 유효 라벨 188,666개(활성 31,273개 16.58%, 비활성 157,393개 83.42%; 활성:비활성 = 1 : 5.03)의 5대 통합 코퍼스를 구성한다(표 2).

분자 수 비중과 양성 신호 기여도는 정반대로 역전되어 있다. MUV는 분자 수의 66.2%(25,000건)를 차지하지만 전체 양성 라벨 31,273개 중 489개(1.56%)만 공급한다. 반면 분자 수 합계가 13.1%(4,946건)

Table 2: 학습 코퍼스 구성: 대조군 V1(단일 MUV)과 실험군 V2(5대 통합 코퍼스 RDKit 전수 파싱 실측)

코퍼스 구분	분자 수(비중)	채널	유효 라벨 수	활성 / 비활성	활성:비활성(기저율)	양성 기여	원자 중앙값(≤ 12/ ≥ 35)	트랩/CSP3
[V1] MUV 원본	93,087건 (-)	17ch	249,886개 (-)	489 / 249,397	1 : 510.01 (0.20%)	-	24 (0.4%/1.9%)	10.7%/0.299
[V2] 1. MUV	25,000건 (66.2%)	17ch	67,274개 (35.7%)	489 / 66,785	1 : 136.57 (0.73%)	1.56%	24 (0.4%/1.9%)	10.8%/0.298
[V2] 2. Tox21	7,823건 (20.7%)	12ch	77,864개 (41.3%)	5,858 / 72,006	1 : 12.29 (7.52%)	18.73%	16 (33.3%/6.4%)	18.6%/0.459
[V2] 3. SIDER	1,427건 (3.8%)	27ch	38,529개 (20.4%)	21,868 / 16,661	1 : 0.76 (56.76%)	**69.93%**	25 (12.7%/20.5%)	34.5%/0.461
[V2] 4. BBBP	2,039건 (5.4%)	1ch	2,039개 (1.1%)	1,560 / 479	1 : 0.31 (76.51%)	4.99%	23 (8.8%/9.4%)	18.3%/0.462
[V2] 5. ClinTox	1,480건 (3.9%)	2ch	2,960개 (1.6%)	1,498 / 1,462	1 : 0.98 (50.61%)	4.79%	23 (11.4%/16.6%)	28.6%/0.466
[V2] 5대 합계	**37,769건 (100%)**	**59ch**	**188,666개 (100%)**	**31,273 / 157,393**	**1:5.03 (16.58%)**	**100.00%**	**23 (8.6% / 4.5%)**	**14.4% / 0.353**

인 SIDER · BBBP · ClinTox 세 유입 코퍼스는 양성 라벨의 79.71%(24,926개)를 공급하며 SIDER 단독으로 69.93%(21,868개)를 차지한다.

5.2 외부 독립 평가 벤치마크와 분포 괴리

외부 평가는 가중치를 동결한 제로샷(Frozen OOD) 추론으로 수행한다. `ogbg-molhiv`(공식 Scaffold Split 테스트셋)는 총 4,113건(활성 130건, 기저율 3.16%)이고, `ogbg-molpcba`(공식 Scaffold Split 테스트셋)는 총 43,793건이며 128개 타깃 중 평가 기준(활성 ≥ 5건, 유효 분자 ≥ 100건)을 충족하는 126개 타깃(평균 기저율 2.56%)을 사용한다(표 3).

Table 3: 학습 통제군(MUV)과 외부 벤치마크 활성 · 비활성 분자군의 분포 이탈 (d_E: 표준화 유클리드 거리, d_M: 마할라노비스 거리)

비교 데이터셋 및 분자군	중원자 중앙값(IQR)	MUV 구간 이탈률	극단 크기 비율	트랩 경계군	FracCSP3 평균	거리 d_E	거리 d_M (OOD ≥ 3.0)
MUV 전체 ($N = 93,087$)	24 (21–28)	46.2%	2.3%	10.7%	0.299	2.07	2.11 (11.2%)
ㄴ MUV 활성 (489 라벨)	24 (21–28)	45.4%	1.9%	20.8%	0.210	2.08	2.13 (12.7%)
ogbg-molhiv 비활성	22 (18–29)	64.5%	20.1%	35.6%	0.359	4.03	3.83 (54.9%)
ㄴ ogbg-molhiv 활성	**36 (21–52)**	**81.5%**	**56.9%**	**61.5%**	0.235	**7.40**	**6.51 (70.8%)**
ogbg-molpcba 비활성	26 (22–31)	53.2%	11.4%	19.1%	0.374	2.85	2.69 (25.9%)
ㄴ ogbg-molpcba 활성	27 (22–31)	**53.6%**	11.8%	**27.3%**	0.295	2.69	2.60 (25.5%)

6 실험 설계와 가설 (Experimental Setup and Hypotheses)

6.1 통제 실험 프로토콜 및 집계 정의

고정 통제 변인. 4계층 GINEConv 백본 아키텍처와 파라미터 수(201,733개), 초기 특징 차원(9D/3D), 옵티마이저(AdamW, lr $= 10^{-3}$, weight_decay $= 10^{-4}$), 전역 시드(seed $= 42$), 외부 평가셋에 대한 가중치 동결 추론을 고정한다.

평가 모드 및 다채널 집계 정의. 외부 벤치마크는 전체 예측(`Total`, L_{total}), 순수 구조(`Struct`, L_{carved}), 물성 단독(`Bias`, L_{bias})의 3가지 모드로 평가한다. 다채널 모델(V2 59채널)을 외부 단일 태스크에 적용할 때, **결합채널(Combined-Channel)** 설정은 대조군 V1과 동일한 기저 생물검정 도메인인 MUV 17개 채널($c \in \{0, \ldots, 16\}$)의 평균 로짓을 사용하며, **59채널 전체 통합(59ch)** 설정은 5대 코퍼스 전체 59개 채널($c \in \{0, \ldots, 58\}$)의 평균 로짓을 사용한다.

6.2 4대 연구 가설

- **H1 (단일 희소 코퍼스의 표현 붕괴 가설):** 극단적 디코이 과잉(1 : 510.01)과 좁은 크기 분포(21 28원자)를 가진 단일 MUV 코퍼스로 학습된 GNN(V1)은 외부 스크리닝 분포에서 구조 로짓 분산이 수축하고 고신뢰 후보($p \geq 0.70$) 발굴이 0건으로 마비되어, 순수 구조 예측력이 무작위 수준(ROC-AUC ≤ 0.50)으로 붕괴할 것이다.
- **H2 (다중 코퍼스 병합 시 집단 교란 가설):** 고밀도 양성 코퍼스(SIDER, BBBP 등)를 단순 병합하면 채널 내부의 직교성($r_{\text{within}} \approx 0$)에도 불구하고 코퍼스 간 기저율 절편 격차($\Delta\mu = 6.10$)가 그룹 간

절편 공분산($\mathrm{Cov}_{\mathrm{between}}$)을 폭증시켜 전체 합산 상관($r_{\mathrm{uncentered}}$)을 부풀리는 집단 교란을 유발할 것이다.

- **H3 (고정 백본 하의 구조 표현력 복원 가설):** 백본 파라미터(201,733개)를 고정한 채 5차원 편향 분리와 채널 중심화 직교 거버넌스(V2)를 적용하면 $\mathrm{Cov}_{\mathrm{between}}$이 0.0000으로 소거되고 구조 로짓 표준편차와 어텐션 집중도(낮은 H_{norm}) 및 우측 고신뢰 활성 꼬리($p \geq 0.70$)가 복원될 것이다.
- **H4 (대규모 가상 스크리닝 조기 인식 도약 및 타깃 감사 가설):** V2의 순수 구조 모드는 `ogbg-molhiv`와 `ogbg-molpcba`(126개 타깃)에서 이론적 상한선(Ceiling) 검증을 만족하며 V1 대비 조기 인식 지표(BEDROC, EF@1%, EF@5%)를 유의미하게 향상시키고, 타깃별 내재 편향 오염도를 3등급(Red/Amber/Green)으로 일관되게 판별해낼 것이다.

7 결과 (Results)

7.1 [H1·H2 검증] 기저율 절편 이동과 전공분산 분해 실증

5대 통합 코퍼스의 코퍼스별 평균 목표 로짓 절편 $\mu_k = \ln(P_k/(1-P_k))$는 표 4와 같다. 양성 기저율은 MUV 0.73%에서 BBBP 76.51%까지 105.26배 차이 나며 절편 이동폭은 $\Delta\mu = 6.0976$이다.

Table 4: 코퍼스별 양성 기저율과 평균 목표 로짓 절편 (최대 기저율 격차 105.26배, 절편 이동폭 $\Delta\mu = 6.0976$)

코퍼스 (채널 수)	양성 기저율 P_k	평균 목표 로짓 절편 μ_k	사전확률 출발선 구분
1. MUV (17ch)	0.73%	−4.9169	강한 음수 절편 (비활성 지배)
2. Tox21 (12ch)	7.52%	−2.6503	중간 음수 절편 (중간 가교)
3. ClinTox (2ch)	50.61%	+0.0941	중립 영점 절편 (1 : 1 균형)
4. SIDER (27ch)	56.76%	+0.2571	양수 절편 (고밀도 양성 공급)
5. BBBP (1ch)	76.51%	+1.1807	강한 양수 절편 (양성 우세)

전공분산 법칙에 따라 59개 채널의 유효 라벨 전체(188,666개)에서 실제 추론된 구조-편향 로짓 공분산을 분해한 결과는 표 5와 같다. 각 채널 내부에서의 순수 공분산 $\mathrm{Cov}_{\mathrm{within}}$은 −0.0177(전체 공분산 절대량의 1.5%)이고 채널 내부 풀링 상관계수는 $r_{\mathrm{within}} = -0.0120$(두 편차 벡터의 사잇각 89.3°)으로 완벽한 직교 상태이다. 반면 채널 간 기저율 절편 공분산 $\mathrm{Cov}_{\mathrm{between}}$은 1.1423으로 전체 공분산 절대량의 98.5%를 차지하며 미보정 합산 상관계수를 $r_{\mathrm{uncentered}} = 0.3574$(초기 학습 중 최대 0.4933)로 부풀리는 집단 교란을 일으켰다. 아키텍처 수준 채널 중심화를 적용하자 $\mathrm{Cov}_{\mathrm{between}} = 0.0000$으로 완벽히 소거되어 순수 직교 상관($r_{\mathrm{within}} = -0.0120$)으로 환원되었다(가설 H2 지지).

Table 5: 59채널 유효 라벨(188,666개) 전공분산 분해와 채널 중심화 전후의 직교성 실측

공분산 및 직교성 평가 구분	그룹 내 ($\mathrm{Cov}_{\mathrm{within}}$)	그룹 간 절편 ($\mathrm{Cov}_{\mathrm{between}}$)	전체 ($\mathrm{Cov}_{\mathrm{total}}$)	내부 상관 (r_{within})	합산 상관 ($r_{\mathrm{uncentered}}$)
1. 채널 중심화 미적용 ($\boldsymbol{\Sigma}_{\mathrm{Total}} = \boldsymbol{\Sigma}_W + \boldsymbol{\Sigma}_B$)	−0.0177 (1.5%)	**1.1423 (98.5% 거품)**	1.1245	−0.0120 (직교)	0.3574 (교란 작시)
2. 채널 중심화 적용 후 (순수 $\boldsymbol{\Sigma}_W$ 추출)	**-0.0177 (100.0%)**	**0.0000 (완벽 소거)**	−0.0177	**-0.0120 (직교)**	**-0.0120 (착시 해소)**

7.2 [H3 검증] 구조 로짓 표현력의 6.8배 확장과 어텐션 샤프닝 (`ogbg-molhiv`)

표 6은 `ogbg-molhiv`($N = 4,113$)에서 동결 가중치 직접 추론으로 두 모델의 내부 표현 상태를 감사한 실측 결과이다. 대조군 V1 순수 구조 모드의 구조 로짓 표준편차는 0.311(범위 −7.95 ∼ −2.09)로 수축하였고 영점정렬 확률이 P10 0.183, P50 0.254, P99 0.331의 좁은 상수 구간에 갇혀 고신뢰 후보($p \geq 0.70$)를 단 한 건도 발굴하지 못하였다(0건, 0.00%). 정규화 어텐션 엔트로피 역시 0.9628 ± 0.0277로 균등 분산 한계(1.0)에 머물렀다. 반면 동일한 201,733개 백본의 V2는 순수 구조 로짓 표준편차를 2.115(범위 −20.29 ∼ −3.62)로 **6.8배 확장**하였고, 정규화 어텐션 엔트로피를 0.7056 ± 0.1545로 대폭 샤프닝하였으며, 우측 고신뢰 활성 꼬리($p \geq 0.70$)에 867건(21.08%)의 후보군을 복원하였다(가설 H1, H3 지지).

Table 6: ogbg-molhiv ($N = 4,113$) 동결 가중치 추론 기반 내부 신경망 표현 상태 감사

모델 및 진단 모드 (ogbg-molhiv, $N = 4,113$)	구조 로짓 표준편차 (Min∼Max)	영점정렬 분위수 (P10 / P50 / P99)	고신뢰 후보 ($p \geq 0.70$)	정규화 어텐션 엔트로피 (H_{norm})
1. 대조군 V1 편향 포함 (Total, 17ch)	0.804 ($-16.88 \sim -1.61$)	0.125/0.280/0.429	0.00% (0건)	0.9628 ± 0.0277 (균등 분산)
2. 대조군 V1 순수 구조 (Struct — 표현 붕괴)	**0.311** ($-7.95 \sim -2.09$)	0.183/0.254/0.331	**0.00% (0건)**	0.9628 ± 0.0277 (균등 분산)
3. 실험군 V2 편향 포함 (Total — 거품 혼입)	2.189 ($-20.03 \sim -4.24$)	0.030/0.173/0.970	20.35% (837건)	0.7056 ± 0.1545 (작용기 샤프닝)
4. 실험군 V2 순수 구조 (Struct — 복원 완성)	**2.115 (6.8배↑)** ($-20.29 \sim -3.62$)	0.035/0.182/0.954	**21.08% (867건)**	**0.7056 ± 0.1545 (샤프닝)**

7.3 [H4 검증 1] ogbg-molhiv 표준 BEDROC 및 상한선 검증

표 7은 ogbg-molhiv($N = 4,113$, 활성 130건, $k_1 = 42, k_5 = 206$)의 실측 검증 결과이며 전 행이 이론적 상한선(Ceiling) 검증을 통과(PASS)하였다.

1. **V1의 붕괴:** V1 순수 구조(Struct)는 ROC-AUC 0.4934($p = 7.99 \times 10^{-1}$)로 귀무가설(AUC = 0.50)을 기각하지 못하며, 상위 1% 적중이 **0건(EF@1% = 0.00×)**, 상위 5% 적중이 6건(EF@5% = 0.92×), BEDROC(80.5) 0.0190, BEDROC(20.0) 0.0460에 그쳤다. 특히 V1 편향 포함(Total)은 물성 단독 헤드의 역전 오염(Bias AUC = 0.3365)에 끌려가며 ROC-AUC 0.3565로 무너졌다.

2. **V2 순수 구조의 도약 및 Total 모드 상회:** V2 순수 구조(결합채널)는 물성 편향의 상위 1% 개입(V2 Bias EF@1% = 0.00×, 0/42건)을 완벽히 차단한 상태에서 ROC-AUC **0.6566**($p = 1.15 \times 10^{-9}$), BEDROC(80.5) **0.2801**(V1 대비 **14.7배**), BEDROC(20.0) **0.3275**(V1 대비 **7.1배**), EF@1% **8.29×(11/42 적중)**, EF@5% **6.45×(42/206 적중**, V1 대비 **7.00배**)로 도약하였다. 특히 물성 거품을 도려낸 V2 순수 구조(Struct)가 편향 포함(Total: AUC 0.6467, BEDROC(80.5) 0.1322, EF@1% 3.01×)보다 모든 지표에서 월등히 높은 성능을 기록하여, 시험관 함정 노이즈 제거가 실제 초기 선별력을 극대화함을 입증하였다.

Table 7: OGB ogbg-molhiv ($N = 4,113$, Active = 130) 표준 BEDROC, EF 및 이론적 상한선(Ceiling) 검증 실측표

모델 및 평가 모드 (ogbg-molhiv)	ROC-AUC (MWU p)	BEDROC(80.5) [Ceil]	BEDROC(20.0) [Ceil]	EF@1% (Hits/42)	EF@5% (Hits/206)	Ceiling 검증
0. V1 편향 포함 (Total, 17ch)	0.3565 (2.44e-08)	0.0125 [≤ 0.0535]	0.0343 [≤ 0.3926]	0.00× (0/42)	0.61× (4/206)	PASS
1. V1 순수 구조 (Struct, 17ch)	0.4934 (7.99e-01)	0.0190 [≤ 0.0704]	0.0460 [≤ 0.4050]	0.00× (0/42)	0.92× (6/206)	PASS
2. V1 물성 단독 (Bias, 17ch)	0.3365 (2.11e-10)	0.0185 [≤ 0.0745]	0.0396 [≤ 0.4009]	0.75× (1/42)	0.77× (5/206)	PASS
3. V2 편향 포함 (Total, 결합채널)	0.6467 (1.19e-08)	0.1322 [≤ 0.2885]	0.2392 [≤ 0.5496]	3.01× (4/42)	4.61× (30/206)	PASS
4. V2 순수 구조 (Struct, 결합채널)	**0.6566** (1.15e-09)	**0.2801** [≤ 0.4430]	**0.3275** [≤ 0.6275]	**8.29× (11/42)**	**6.45× (42/206)**	PASS
5. V2 물성 단독 (Bias, 결합채널)	0.4865 (6.01e-01)	0.0172 [≤ 0.0621]	0.0581 [≤ 0.3988]	**0.00× (0/42)**	0.77× (5/206)	PASS
6. V2 순수 구조 (59ch 전체 통합)	**0.6567** (1.13e-09)	**0.1966** [≤ 0.3000]	**0.2996** [≤ 0.5977]	0.75× (1/42)	**6.45× (42/206)**	PASS

7.4 [H4 검증 2] ogbg-molpcba 126개 유효 타깃 전수 비교 및 3등급 신호등 감사

표 8은 ogbg-molpcba($N = 43,793$, 평가 126/128개 타깃)의 타깃 평균 지표이다. 대조군 V1 순수 구조는 평균 ROC-AUC 0.4607로 무작위 기준(0.50) 미만의 역전 붕괴를 보였으나, V2 순수 구조는 평균 ROC-AUC를 0.5050(결합채널) 및 0.5073(59ch 통합)으로 복원하였으며 Mean BEDROC(80.5)를 0.0481에서 0.0519(결합채널) / 0.0518(59ch)로, Mean EF@1%를 V1 Total(1.91×) 대비 2.33×(결합채널) / 2.31×(59ch)로 향상시켰다.

Table 8: OGB ogbg-molpcba ($N = 43,793$, 126개 유효 타깃) 전수 평균 비교 실측표

모델 및 평가 모드 (ogbg-molpcba)	Mean ROC-AUC	Mean BEDROC(80.5)	Mean BEDROC(20.0)	Mean EF@1%	Mean EF@5%	평가 타깃
0. V1 편향 포함 (Total, 17ch)	0.5144	0.0481	0.0887	1.91×	1.42×	126/128
1. V1 순수 구조 (Struct, 17ch — 역전 붕괴)	**0.4607** (< 0.50)	0.0481	0.0863	2.30×	1.62×	126/128
2. V1 물성 단독 (Bias, 17ch)	0.5612	0.0536	0.1055	1.68×	1.68×	126/128
3. V2 편향 포함 (Total, 결합채널)	0.5180	0.0559	0.0955	2.39×	1.62×	126/128
4. V2 순수 구조 (Struct, 결합채널)	**0.5050** (+0.0443 ↑)	**0.0519**	**0.0882**	**2.33×**	1.47×	126/128
5. V2 물성 단독 (Bias, 결합채널)	0.5682	0.0481	0.0949	1.37×	1.36×	126/128
6. V2 순수 구조 (59ch 전체 통합)	**0.5073** (+0.0466 ↑)	**0.0518**	0.0858	**2.31×**	1.46×	126/128

표 9는 126개 타깃을 판정 규칙(Red: $A_{\text{bias}} > A_{\text{V1}}$ 이고 $A_{\text{bias}} \geq 0.55$; Amber: $A_{\text{V1}} < 0.45$ 이고 $A_{\text{V2}} - A_{\text{V1}} > 0.05$; Green: 그 외 정합 타깃)에 따라 3등급으로 분류한 결과이다.

- **Tier 1 (Red, 지름길 오염 타깃 — 80개, 63.5%):** 물성 단독 AUC가 0.6166에 달해 V1에서는 구조 인코더가 신호를 빼앗기며 구조 AUC가 0.4419로 역전 붕괴되어 있었으나, V2 직교 거버넌스를 통해 물성 간섭을 분리하자 순수 구조 AUC가 0.5193(+0.0774 ↑)으로 복원되었다.
- **Tier 2 (Amber, 분포 불일치 타깃 — 6개, 4.8%):** 물성 편향은 낮으나(0.4705) MUV 온실 분포와의 괴리로 인해 V1에서 0.3856으로 가장 심하게 무너졌던 타깃군으로, 5대 코퍼스 5축 정렬 후 0.5003(+0.1147 ↑)으로 가장 큰 폭의 구조 복원을 달성하였다.
- **Tier 3 (Green, 모델 정합 양호 타깃 — 40개, 31.7%):** 물성 편향(0.4860)이 억제된 상태에서 안정적인 구조 판별력(V1 0.5097, V2 0.4845)을 유지하는 타깃군이다.

특히 표 9의 3등급 타깃 수(80, 6, 40개)로 가중평균을 계산하면 V1 구조 AUC는 $(80 \times 0.4419 + 6 \times 0.3856 + 40 \times 0.5097)/126 = \mathbf{0.4607}$, V2 구조 AUC는 $(80 \times 0.5193 + 6 \times 0.5003 + 40 \times 0.4845)/126 = \mathbf{0.5073}$, 물성 단독 AUC는 **0.5682**가 되어 **표 8의 126개 전체 평균 수치와 소수점 넷째 자리까지 100% 일치**한다.

Table 9: AX 데이터 거버넌스 신호등(Signal-Light): `ogbg-molpcba` 126개 타깃의 3등급 분류 (표 8과 가중평균 100% 일치)

AX 데이터 거버넌스 신호등 등급 (126개 타깃)	타깃 수 (비율)	미정렬 구조 (V1)	정렬 후 구조 (V2)	물성 단독 (Bias)	평균 복원폭 (V2−V1)
Tier 1 (Red): 지름길 오염 타깃 (탈편향 강제)	80개 (63.5%)	0.4419	**0.5193**	**0.6166**	**+0.0774 (역전 탈출)**
Tier 2 (Amber): 분포 불일치 타깃 (5축 정렬 복원)	6개 (4.8%)	0.3856	**0.5003**	0.4705	**+0.1147 (최대 복원)**
Tier 3 (Green): 모델 정합 양호 타깃 (스크리닝 유효)	40개 (31.7%)	0.5097	0.4845	0.4860	−0.0252 (정제 유지)
[검산] 126개 타깃 전체 가중평균 (표 8과 일치)	**126개 (100%)**	**0.4607**	**0.5073**	**0.5682**	**+0.0466**

7.5 가설 검증 요약

본 연구의 4대 가설에 대한 실증 결과와 판정 요약은 표 10과 같다.

Table 10: 연구 가설(H1–H4)별 핵심 실증 근거와 최종 판정

가설	검증 대상	핵심 실증 근거 (동결 가중치 실측치)	판정
H1	표현 붕괴	V1 구조 로짓 표준편차 0.311 수축, $p \geq 0.70$ 후보 0건(0.00%), $H_{\text{norm}} = 0.9628$, `molhiv` 구조 AUC 0.4934($p = 0.799$, EF@1% 0.00×), `molpcba` 평균 0.4607 (< 0.50).	**지지**
H2	집단 교란	5대 코퍼스 기저율 격차 105.26배 ($\Delta\mu = 6.0976$), $\text{Cov}_{\text{between}} = 1.1423$(98.5% 거품) 대 $\text{Cov}_{\text{within}} = -0.0177$(1.5%, $r_{\text{within}} = -0.0120$), 미보정 상관 0.3574 왜곡 규명.	**지지**
H3	표현력 복원	동일 201,733개 백본에서 V2 구조 로짓 표준편차 0.311 → 2.115(6.8배 확장), $H_{\text{norm}} = 0.9628 \rightarrow 0.7056$ 샤프닝, $p \geq 0.70$ 고신뢰 후보 0건 → 867건(21.08%) 복원.	**지지**
H4	조기 인식·감사	전 행 Ceiling 검증 `PASS`; `molhiv` V2 순수 구조 AUC 0.6566, BEDROC(80.5) 0.2801(14.7배), EF@1% 8.29×(11/42), EF@5% 6.45×(7.0배)로 `Total` 모드까지 상회; `molpcba` 126개 타깃 3등급 분류 및 가중평균(0.4607 → 0.5073) 완벽 일치.	**지지**

8 논의 (Discussion)

8.1 연구 결과 해석의 범위: 가중치 배포가 아닌 방법론의 개념 증명

본 연구에서 생성한 동결 가중치(`benchscope_frozen_auditor.pt` 859.6 KB, `benchscope_multi_v2_frozen.pt` 875.0 KB)는 제안한 4단계 데이터 거버넌스 방법론이 구조 표현 붕괴를 완화하고 조기 인식 성능을 복원할 수 있는지를 통제 조건에서 확인하기 위한 개념 증명(PoC) 프로토타입이다. 제약 기업이나 다기관 데이터

플랫폼이 본 연구를 현업에 적용할 때에는 공개 데이터셋으로 학습된 가중치를 단순 재사용하는 것이 아니라, 사내 독자 화합물 라이브러리(Proprietary Library)와 사내 백본 모델 위에 본 4단계 직교 거버넌스 절차(5축 편향 텐서 분리, 3층위 채널 중심화, 절편 보존 추론, Ceiling 검증)를 이식하여 자체 감사 체계를 구축해야 한다.

8.2 교란 요인 통제의 엄밀성과 백본 고정 설계의 정당성

V1에서 V2로 개선하면서 GNN 층 수나 은닉 차원을 함께 늘렸다면, 성능 향상(`ogbg-molhiv` 0.4934 → 0.6566, EF@5% 0.92× → 6.45×)이 모델 용량 증가 때문인지 데이터 정렬과 직교 거버넌스 때문인지 인과적으로 분리할 수 없다. 본 연구는 백본 아키텍처와 파라미터 수를 201,733개로 100% 고정하여 모델 용량이라는 주요 교란 변인을 통제하였고, 증가한 3,980개(+1.88%)는 출력 헤드에 한정하였다. 특히 `ogbg-molhiv`에서 물성 편향 성분을 제거한 V2 순수 구조 모드(EF@1% 8.29×, EF@5% 6.45×)가 편향 포함 모드(`Total`: EF@1% 3.01×, EF@5% 4.61×)보다 훨씬 높은 조기 인식률을 달성한 것은, 시험관 함정(Assay Trap) 노이즈를 도려내었을 때 진성 활성 물질들이 최상위 1% 구간으로 부상함을 보여주는 강력한 실증 근거이다.

8.3 연구의 한계점 및 후속 연구 방향

1. **물성 기준선과의 관계 및 타깃별 이질성:** `ogbg-molpcba` 126개 타깃 중 Red 등급(80개, 63.5%)에서는 여전히 물성 단독 AUC(0.6166)가 구조 AUC(0.5193)보다 높게 나타난다. 이는 고속 스크리닝(HTS) 벤치마크 자체에 내재한 물리화학적 아티팩트가 그만큼 강력함을 방증하며, 바로 이러한 타깃들을 사전에 식별해 Wet-lab 매몰 비용을 차단하는 것이 본 3등급 신호등 감사의 핵심 목적이다.

2. **경량 2D GINEConv 백본의 절대 성능 상한:** 통제 실험을 위해 채택한 4계층 2D GINEConv는 3차원 등변 신경망(3D Equivariant GNN)이나 그래프 트랜스포머 대비 절대 예측 성능이 가장 높은 SOTA 백본은 아니다. 그러나 양갈래 직교 헤드와 구조적 중심화 레이어는 백본 무관(Backbone-Agnostic) 플러그인 모듈이므로, 후속 연구에서 SOTA 파운데이션 백본에 결합하여 절대 스크리닝 성능을 극대화할 수 있다.

3. **타깃 단백질 3D 결합 포켓 정보 및 모달리티 확장:** 현재 프로토타입은 리간드 2D 분자 그래프만을 입력받으므로 단백질 포켓과의 유도 적합(Induced Fit)을 직접 계산하지 못하며, 트랩 임계값($\mathrm{LogP} > 5.0, \mathrm{TPSA} > 120$ Å^2, $\mathrm{FracCSP3} \leq 0.15$)은 저분자 합성 신약에 맞추어져 있다. 향후 단백질-리간드 3D 복합체 그래프로의 확장 및 PROTAC·거대고리 펩타이드 등 중분자 모달리티에 맞춘 적응형 영점 재보정 연구가 필요하다.

9 결론 (Conclusion)

본 연구는 신약 개발 AI 도입에서 반복되는 벤치마크 착시와 습식 검증 실패의 핵심 원인이 신경망 내부의 지름길 유도 구조 표현 붕괴와 다중 데이터 통합 시의 기저율 절편 집단 교란에 있음을 수리적·실증적으로 규명하였다. 이를 해결하기 위해 제안한 `NonCircularBenchScopeGNN` 기반 4단계 데이터 거버넌스 방법론은, 201,733개 백본 파라미터를 100% 고정한 통제 조건에서 구조 로짓 표준편차를 0.311에서 2.115로(6.8배) 복원하고 채널 간 절편 공분산(1.1423, 98.5% 거품)을 0.0000으로 소거하였으며, 외부 벤치마크에서 순수 구조 모드의 조기 인식 지표를 획기적으로 향상시켰다(`ogbg-molhiv`: ROC-AUC 0.4934 → 0.6566, BEDROC(80.5) 0.0190 → 0.2801 [14.7배], EF@1% 0.00× → 8.29×, EF@5% 0.92× → 6.45× [7.00배]; `ogbg-molpcba` 126개 타깃: 평균 구조 ROC-AUC 0.4607 → 0.5073, 3등급 신호등 가중평균 완벽 일치). 본 방법론은 고위험 제약·바이오 R&D 조직 및 다기관 데이터 플랫폼이 신뢰할 수 있는 AX 의사결정 지원 체계를 구축하는 데 실질적인 이론적·실무적 기반을 제공한다.

사사 (Acknowledgments)

본 연구는 과학기술정보통신부의 다기관 의료 데이터 연구 지원을 위한 의료 데이터 스페이스 구축 사업의 문제의식에서 영감을 받아 수행되었으며, 외부의 별도 재정적 지원 없이 수행되었다. 실증 분석에 활용된 공개 분자 벤치마크 데이터셋을 제공한 MoleculeNet 및 Stanford Open Graph Benchmark(OGB) 연구진과 오픈소스 화학정보학 도구인 RDKit 및 PyTorch Geometric 개발 커뮤니티에 감사를 표한다.

References

[1] Rohrer, S. G., & Baumann, K. (2009). Maximum unbiased validation (MUV) data sets for virtual screening based on PubChem bioactivity data. *Journal of Chemical Information and Modeling*, 49(2), 169–184.

[2] Truchon, J.-F., & Bayly, C. I. (2007). Evaluating virtual screening methods: good and bad metrics for the "early recognition" problem. *Journal of Chemical Information and Modeling*, 47(2), 488–508.

[3] Hu, W., Fey, M., Zitnik, M., Dong, Y., Ren, H., Liu, B., Catasta, M., & Leskovec, J. (2020). Open Graph Benchmark: Datasets for machine learning on graphs. *Advances in Neural Information Processing Systems* (*NeurIPS*), 33, 22118–22133.

[4] Wu, Z., Ramsundar, B., Feinberg, E. N., Gomes, J., Geniesse, C., Pappu, A. S., Leswing, K., & Pande, V. (2018). MoleculeNet: a benchmark for molecular machine learning. *Chemical Science*, 9(2), 513–530.

[5] Mysinger, M. M., Carchia, M., Irwin, J. J., & Shoichet, B. K. (2012). Directory of useful decoys, enhanced (DUD-E): better ligands and decoys for better benchmarking. *Journal of Medicinal Chemistry*, 55(14), 6582–6594.

[6] Baell, J. B., & Holloway, G. A. (2010). New substructure filters for removal of pan assay interference compounds (PAINS) from screening libraries and for their exclusion in bioassays. *Journal of Medicinal Chemistry*, 53(7), 2719–2740.

[7] Irwin, J. J., Duan, D., Torosyan, H., Doak, A. K., Ziebart, K. T., Sterling, T., Tumanian, G., & Shoichet, B. K. (2015). An aggregation advisor for ligand discovery. *Journal of Medicinal Chemistry*, 58(17), 7076–7087.

[8] Lovering, F., Bikker, J., & Humblet, C. (2009). Escape from flatland: increasing saturation as an approach to improving clinical success. *Journal of Medicinal Chemistry*, 52(21), 6752–6756.

[9] Geirhos, R., Jacobsen, J.-H., Michaelis, C., Zemel, R., Brendel, W., Bethge, M., & Wichmann, F. A. (2020). Shortcut learning in deep neural networks. *Nature Machine Intelligence*, 2(11), 665–673.

[10] Xu, K., Li, C., Tian, Y., Sonobe, T., Kawarabayashi, K., & Jegelka, S. (2018). Representation learning on graphs with jumping knowledge networks. *Proceedings of the 35th International Conference on Machine Learning* (*ICML*), PMLR 80, 5453–5462.

[11] Bemis, G. W., & Murcko, M. A. (1996). The properties of known drugs. 1. Molecular frameworks. *Journal of Medicinal Chemistry*, 39(15), 2887–2893.

[12] Hevner, A. R., March, S. T., Park, J., & Ram, S. (2004). Design science in information systems research. *MIS Quarterly*, 28(1), 75–105.

[13] Xu, K., Hu, W., Leskovec, J., & Jegelka, S. (2019). How powerful are graph neural networks? *International Conference on Learning Representations* (*ICLR*).

[14] Hu, W., Liu, B., Gomes, J., Zitnik, M., Liang, P., Pande, V., & Leskovec, J. (2020). Strategies for pre-training graph neural networks. *International Conference on Learning Representations* (*ICLR*).

[15] Robinson, W. S. (1950). Ecological correlations and the behavior of individuals. *American Sociological Review*, 15(3), 351–357.

[16] Simpson, E. H. (1951). The interpretation of interaction in contingency tables. *Journal of the Royal Statistical Society: Series B*, 13(2), 238–241.

[17] Mahalanobis, P. C. (1936). On the generalised distance in statistics. *Proceedings of the National Institute of Sciences of India*, 2(1), 49–55.

[18] Wallach, I., & Heifets, A. (2018). Most ligand-based classification benchmarks reward memorization rather than generalization. *Journal of Chemical Information and Modeling*, 58(5), 916–932.

[19] Chen, L., Cruz, A., Ramsey, S., Dickson, C. J., Duca, J. S., Hornak, V., Koes, D. R., & Kurtzman, T. (2019). Hidden bias in the DUD-E dataset leads to misleading performance of deep learning in structure-based virtual screening. *PLoS ONE*, 14(8), e0220113.

A 수리적 증명 (Mathematical Proofs)

A.1 전공분산 법칙에 의한 다중 코퍼스 절편 교란의 분해와 채널 중심화에 의한 소거

확률변수 쌍 (S, B)가 채널 인덱스 $T \in \{1, \ldots, 59\}$에 조건부로 분포하고 $\mathbb{E}[S] = \mu_S, \mathbb{E}[B] = \mu_B$라 하자. 전공분산 법칙(Law of Total Covariance)에 의해 다음이 성립한다:

$$\begin{aligned}\mathrm{Cov}_{\mathrm{total}}(S, B) &= \mathbb{E}_T\Big[\mathbb{E}\big[(S - \mathbb{E}[S \mid T])(B - \mathbb{E}[B \mid T]) \;\big|\; T\big]\Big] + \mathbb{E}_T\Big[(\mathbb{E}[S \mid T] - \mu_S)(\mathbb{E}[B \mid T] - \mu_B)\Big] \\ &= \mathbb{E}_T\big[\mathrm{Cov}_{\mathrm{within}}(S_t, B_t)\big] + \mathrm{Cov}_{\mathrm{between}}(\mu_{S,t}, \mu_{B,t}) \end{aligned} \tag{20}$$

아키텍처 수준의 채널 중심화 연산 $\hat{z}_{S,i,t} = S_{i,t} - \mathbb{E}[S \mid T = t]$, $\hat{z}_{B,i,t} = B_{i,t} - \mathbb{E}[B \mid T = t]$를 적용하면 모든 채널 $t \in \{1, \ldots, 59\}$에서 조건부 기댓값 $\mathbb{E}[\hat{z}_S \mid T = t] = 0$, $\mathbb{E}[\hat{z}_B \mid T = t] = 0$이 성립한다. 따라서 둘째 항은 $\mathrm{Cov}_{\mathrm{between}}(0, 0) = 0$으로 항등적으로 소거되고 $\mathrm{Cov}_{\mathrm{total}}(\hat{z}_S, \hat{z}_B) = \mathbb{E}_T[\mathrm{Cov}_{\mathrm{within}}(S_t, B_t)]$가 되어, 그룹 간 기저율 차이(1.1423)에 완벽히 불변(Invariant)인 순수 내부 공분산(-0.0177)만 남는다.

A.2 마할라노비스 거리와 채널 중심화 직교 정규화의 동치성

채널 중심화로 그룹 간 분산 행렬 $\mathbf{\Sigma}_B = \mathbf{0}$이 제거된 상태에서, 채널별 표준편차 $\sigma_{S,t}, \sigma_{B,t}$로 정규화한 2차원 잔차 벡터 $\mathbf{z}_{i,t} = [\hat{z}_{S,i,t}/\sigma_{S,t},\ \hat{z}_{B,i,t}/\sigma_{B,t}]^\top$의 그룹 내 공분산 행렬(상관 행렬)은 $\mathbf{\Sigma}_W = \begin{bmatrix} 1 & r_{\mathrm{within}} \\ r_{\mathrm{within}} & 1 \end{bmatrix}$이다. 이때 원점으로부터의 제곱 마할라노비스 거리는 다음과 같다:

$$d_M^2(\mathbf{z}) = \mathbf{z}^\top \mathbf{\Sigma}_W^{-1} \mathbf{z} = \frac{1}{1 - r_{\mathrm{within}}^2}\left(z_S^2 - 2 r_{\mathrm{within}} z_S z_B + z_B^2\right) \tag{21}$$

직교 정규화 손실 $\mathcal{L}_{\mathrm{ortho}}$가 수렴하여 $r_{\mathrm{within}} \to 0$이 되면 $\mathbf{\Sigma}_W \to \mathbf{I}_2$(단위 대각 행렬)가 되므로 $d_M^2(\mathbf{z}) \to z_S^2 + z_B^2$가 되어, 마할라노비스 거리 공간과 표준화 유클리드 직교 공간이 극한에서 일치한다. 본 연구의 실측값 $r_{\mathrm{within}} = -0.0120$에서 보정 계수 $1/(1 - r_{\mathrm{within}}^2) = 1.00014$이므로 두 거리의 차이는 0.014% 미만으로 완전히 일치한다.

A.3 상위 적중 건수(EF@1%, EF@5%) 제약 하의 BEDROC 이론적 상한선 유도

전체 분자 수 N, 전체 활성 수 n, 상위 1%($k_1 = \lceil 0.01N \rceil$)의 적중 활성 수 h_1, 상위 5%($k_5 = \lceil 0.05N \rceil$)의 적중 활성 수 h_5가 주어졌을 때, 단조 감소 함수 $\exp(-\alpha r/N)$의 합 $\sum_{i=1}^{n} \exp(-\alpha r_i/N)$을 최대화하는 최적 순위 배치 $\mathbf{r}^*$는 각 구간 내 활성 분자가 가능한 가장 앞선 순위를 차지할 때 달성된다:

- 구간 1 (상위 1% 내부, h_1개): $r^* = 1, 2, \ldots, h_1$
- 구간 2 (상위 1% $\sim$ 5% 내부, $h_5 - h_1$개): $r^* = k_1 + 1, k_1 + 2, \ldots, k_1 + (h_5 - h_1)$
- 구간 3 (상위 5% 이후 나머지, $n - h_5$개): $r^* = k_5 + 1, k_5 + 2, \ldots, k_5 + (n - h_5)$

이 $\mathbf{r}^*$를 식 (18)–(19)에 대입한 $\mathrm{BEDROC_Ceil}(h_1, h_5; \alpha)$는 주어진 EF@1% $\cdot$ EF@5%를 갖는 어떤 모델도 넘을 수 없는 수학적 상한선이며, 표 7의 모든 행은 $\mathrm{BEDROC}_{\mathrm{observed}} \le \mathrm{BEDROC_Ceil}$을 만족한다(PASS).

B 구현 세부사항 및 재현성 체크리스트

- **개발 및 실행 환경:** Python 3.10+, PyTorch 2.6+ (`weights_only=False` 호환 패치 적용), PyTorch Geometric (PyG), RDKit, scikit-learn, SciPy. 전역 난수 시드 seed = 42 (`torch.backends.cudnn.deterministic = True`).

- **가중치 체크포인트 명세:** 대조군 V1(benchscope_frozen_auditor.pt, 859.6 KB, 총 211,463 파라미터) 및 실험군 V2(benchscope_multi_v2_frozen.pt, 875.0 KB, 총 215,443 파라미터). 무파라미터 채널 중심화 계층(StructuralChannelCentering)은 persistent=False 버퍼를 사용하여 기존 76개 state_dict 텐서 체크포인트와 100% 호환 로드된다.

C 핵심 구현 코드 (Core Implementation Code)

아래는 핵심 아키텍처(NonCircularBenchScopeGNN), 무파라미터 채널 중심화 계층(StructuralChannelCentering), 그리고 표준 BEDROC 및 이론적 상한선(bedroc_ceiling) 검증 함수의 파이썬 원형 코드이다.

```
import math
import numpy as np
import torch
import torch.nn as nn
import torch.nn.functional as F
from torch_geometric.nn import GINEConv, JumpingKnowledge
from torch_geometric.utils import softmax

class StructuralChannelCentering(nn.Module):
    """[Layer-1 Governance] Zero-parameter structural channel-centering projection."""
    def __init__(self, num_channels, momentum=0.1):
        super().__init__()
        self.register_buffer('running_mean', torch.zeros(1, num_channels), persistent=False)
        self.register_buffer('initialized', torch.tensor(False, dtype=torch.bool), persistent=False)
        self.momentum = momentum

    def forward(self, z):
        if self.training and z.size(0) > 1:
            b_mean = z.mean(dim=0, keepdim=True)
            with torch.no_grad():
                if not self.initialized:
                    self.running_mean.copy_(b_mean)
                    self.initialized.fill_(True)
                else:
                    self.running_mean.mul_(1.0 - self.momentum).add_(b_mean * self.momentum)
            return z - b_mean
        return z - (z.mean(dim=0, keepdim=True) if z.size(0) >= 2 else self.running_mean)


class NonCircularBenchScopeGNN(nn.Module):
    """Fixed 201,733-parameter GINEConv backbone with orthogonal structural and bias heads."""
    def __init__(self, num_tasks=59, bias_dim=5, bias_hidden=24):
        super().__init__()
        self.node_emb = nn.Linear(9, 128)
        self.edge_emb = nn.Linear(3, 128)
        self.convs = nn.ModuleList([
            GINEConv(nn.Sequential(
                nn.Linear(128, 128), nn.BatchNorm1d(128), nn.ReLU(), nn.Linear(128, 128)
            ), train_eps=True) for _ in range(4)
        ])
        self.bns = nn.ModuleList([nn.BatchNorm1d(128) for _ in range(4)])
        self.jk = JumpingKnowledge(mode='cat')
        self.jk_linear = nn.Linear(512, 128)
        self.att_gate = nn.Linear(128, 1)

        self.structural_head = nn.Sequential(
            nn.Linear(128, 64), nn.ReLU(), nn.Dropout(0.2), nn.Linear(64, num_tasks)
```

```
        )
        self.bias_only_head = nn.Sequential(
            nn.Linear(bias_dim, bias_hidden), nn.ReLU(), nn.Linear(bias_hidden, num_tasks)
        )
        self.center_s = StructuralChannelCentering(num_tasks)
        self.center_b = StructuralChannelCentering(num_tasks)

    def forward(self, data, mol_tau=None, mol_bias_feat=None, apply_centering=True):
        x = F.relu(self.node_emb(data.x[:, :9].float()))
        e = F.relu(self.edge_emb(data.edge_attr[:, :3].float()))
        xs = []
        for conv, bn in zip(self.convs, self.bns):
            x = F.relu(bn(conv(x, data.edge_index, e)))
            xs.append(x)
        h_jk = F.relu(self.jk_linear(self.jk(xs)))

        raw_att = self.att_gate(h_jk).squeeze(-1)
        if mol_tau is None:
            n_nodes = torch.bincount(data.batch, minlength=data.num_graphs).float().clamp(min=6.0)
            mol_tau = torch.sqrt(24.0 / n_nodes).clamp(min=0.45, max=1.35)
        raw_att = raw_att / mol_tau[data.batch].clamp(min=0.45, max=1.35)
        alpha = softmax(raw_att, data.batch)

        z_graph = torch.zeros(data.num_graphs, 128, device=h_jk.device)
        z_graph.index_add_(0, data.batch, h_jk * alpha.unsqueeze(-1))

        raw_s = self.structural_head(z_graph)
        raw_b = (self.bias_only_head(mol_bias_feat.float())
                 if mol_bias_feat is not None else torch.zeros_like(raw_s))

        if apply_centering and raw_s.size(0) > 1:
            prior_b_c = raw_s.mean(dim=0, keepdim=True) + raw_b.mean(dim=0, keepdim=True)
            z_hat_s, z_hat_b = self.center_s(raw_s), self.center_b(raw_b)
            return z_hat_s + z_hat_b + prior_b_c, z_hat_s + prior_b_c, z_hat_b + prior_b_c
        return raw_s + raw_b, raw_s, raw_b


def bedroc(ranks, N, alpha=80.5):
    """Truchon & Bayly (2007). ranks: 1-based ranks of the n actives among N molecules."""
    r = np.asarray(ranks, dtype=np.float64)
    n = r.size
    Ra = n / N
    rie = (np.exp(-alpha * r / N).sum() / n) / ((1.0 / N) * (1.0 - np.exp(-alpha)) / (np.exp(alpha / N) - 1.0))
    val = (rie * Ra * np.sinh(alpha / 2.0) / (np.cosh(alpha / 2.0) - np.cosh(alpha / 2.0 - alpha * Ra))
           + 1.0 / (1.0 - np.exp(alpha * (1.0 - Ra))))
    return float(np.clip(val, 0.0, 1.0))


def bedroc_ceiling(N, n, h1, h5, alpha=80.5):
    """Theoretical upper bound of BEDROC given h1 hits in top 1% and h5 hits in top 5%."""
    k1, k5 = math.ceil(0.01 * N), math.ceil(0.05 * N)
    ranks = (list(range(1, h1 + 1))
             + list(range(k1 + 1, k1 + 1 + max(0, h5 - h1)))
             + list(range(k5 + 1, k5 + 1 + max(0, n - h5))))[:n]
    return bedroc(ranks, N, alpha)
```